HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP LỚN

MÔN HỌC: HỆ CƠ SỞ DỮ LIỆU ĐA PHƯƠNG TIỆN

ĐỀ TÀI

XÂY DỰNG HỆ CSDL LƯU TRỮ VÀ TÌM KIẾM ẢNH CÂY THÂN GỖ THEO NỘI DUNG

Giảng viên hướng dẫn: Nguyễn Đình Hóa

Nhóm 27 – D23 – Lớp 2

STT	Họ và tên	Mã sinh viên
1	Nguyễn Văn Đăng	B23DCCN119
2	Trịnh Anh Tú	B23DCCN876
3	Trần Việt Anh	B23DCCN050

Hà Nội, 2026

MỤC LỤC

1. Giới thiệu bài toán và phạm vi thực hiện

2. Xây dựng bộ dữ liệu ảnh cây thân gỗ (Nội dung 1)

   2.5. Định lượng điểm giống và khác nhau theo chi cây

3. Các bộ đặc trưng nhận diện cây (Nội dung 2)

   3.6. Đánh giá định lượng giá trị thông tin của các đặc trưng

   3.7. Ví dụ minh hoạ: đặc trưng tìm sự tương đồng và sự khác biệt

4. Trích rút đặc trưng và hệ CSDL quản trị đặc trưng (Nội dung 3)

5. Hệ thống tìm kiếm ảnh tương đồng (Nội dung 4)

   5.1. Sơ đồ khối, chức năng và dữ liệu vào/ra của từng khối; quy trình thực hiện

   5.2. Minh hoạ kết quả trung gian của quá trình truy vấn

   5.3. Đánh giá kết quả

6. Demo hệ thống (Nội dung 5)

7. Kết luận và hướng phát triển

Phụ lục A. Cấu trúc mã nguồn và hướng dẫn chạy

Phụ lục B. Trích danh sách nguồn ảnh

1. Giới thiệu bài toán và phạm vi thực hiện

1.1. Bối cảnh

Khác với cơ sở dữ liệu truyền thống chủ yếu trả lời các truy vấn khớp chính xác trên thuộc tính có cấu trúc, hệ cơ sở dữ liệu đa phương tiện (MMDB) phải quản lý các đối tượng ảnh, âm thanh, video có kích thước lớn cùng với siêu dữ liệu mô tả và vector đặc trưng; truy vấn điển hình là tìm kiếm tương đồng ("tìm các ảnh giống ảnh này") và kết quả được xếp hạng thay vì chỉ lọc bản ghi. Vì ngữ nghĩa của ảnh không được biểu diễn tường minh trong chuỗi byte, việc lưu trữ, lập chỉ mục và truy vấn phải kết hợp kỹ thuật cơ sở dữ liệu, xử lý tín hiệu và các kỹ thuật truy vấn theo chỉ mục.

Tra cứu ảnh dựa trên nội dung (Content-Based Image Retrieval, CBIR) đi theo hai giai đoạn: giai đoạn ngoại tuyến nhập ảnh, chuẩn hoá, trích rút đặc trưng và xây dựng chỉ mục; giai đoạn trực tuyến xử lý ảnh truy vấn theo cùng cách thức, so sánh tương đồng dựa trên đặc trưng, xếp hạng và trả về kết quả. Ba lựa chọn kỹ thuật cơ bản của một hệ CBIR là: thuộc tính mô tả (đặc trưng), thước đo khoảng cách và chiến lược cắt tỉa ứng viên.

1.2. Yêu cầu của đề bài

1. Xây dựng/sưu tầm bộ dữ liệu ít nhất 500 ảnh cây thân gỗ trưởng thành, cùng kích thước, mỗi ảnh gồm một cây hoàn chỉnh nằm giữa ảnh, chụp ngang, tỉ lệ khung hình của vật thể tương đồng; mô tả đặc điểm giống và khác nhau của các cây trong ảnh.
2. Xây dựng một hoặc vài bộ đặc trưng để nhận diện cây, bao gồm các đặc trưng giúp tìm sự tương đồng và sự khác biệt; trình bày từng loại đặc trưng và giá trị thông tin của chúng.
3. Triển khai thuật toán/công cụ trích rút đặc trưng và xây dựng hệ CSDL quản trị đặc trưng của toàn bộ ảnh.
4. Triển khai hệ thống tìm kiếm ảnh tương đồng: đầu vào là một ảnh cây mới, đầu ra là 5 ảnh giống nhất xếp theo độ tương đồng giảm dần; trình bày sơ đồ khối, chức năng và dữ liệu vào/ra của từng khối, minh hoạ kết quả trung gian và đánh giá kết quả.
5. Demo hệ thống.

1.3. Phạm vi và công cụ

Hệ thống được cài đặt hoàn chỉnh bằng Python 3.12 với các thư viện xử lý ảnh (OpenCV, scikit-image, Pillow), tính toán (NumPy, SciPy), cơ sở dữ liệu quan hệ SQLite (thư viện chuẩn), suy diễn mạng nơ-ron ONNX Runtime và giao diện demo Streamlit. Bộ dữ liệu sau khi sưu tầm, lọc và kiểm duyệt gồm 627 ảnh trong CSDL và 10 ảnh truy vấn thử được tách riêng (không nằm trong CSDL). Toàn bộ mã nguồn, dữ liệu, CSDL đặc trưng và kết quả đánh giá được đóng gói trong một kho mã nguồn duy nhất, có thể chạy lại từng bước bằng các script trong thư mục scripts/ (Phụ lục A).

Bảng 1. Công nghệ sử dụng

Thành phần	Công nghệ / thư viện	Vai trò
Sưu tầm ảnh	MediaWiki API (Wikimedia Commons), urllib	Duyệt category, lấy siêu dữ liệu, tải ảnh
Tiền xử lý	Pillow, NumPy, OpenCV (pHash)	Chuẩn hoá kích thước, khử trùng lặp
Phân đoạn	SegFormer-b0 ADE20K (ONNX), OpenCV GrabCut, SciPy	Tách vùng cây / nền
Đặc trưng thủ công	OpenCV, scikit-image	Màu sắc, hình dạng, kết cấu/bố cục
Đặc trưng sâu	ONNX Runtime + MobileNetV2 (ImageNet)	Embedding 1280 chiều
CSDL đặc trưng	SQLite (sqlite3)	Bảng quan hệ + vector BLOB + chỉ mục
Chỉ mục đa chiều	PCA (SVD, NumPy), cKDTree (SciPy), K-means (NumPy)	Cắt tỉa ứng viên
Đánh giá & hình	NumPy, Matplotlib	P@5, mAP, so sánh backend, hình minh hoạ
Demo	Streamlit, CLI	Giao diện tải ảnh và xem kết quả
Báo cáo	python-docx, LibreOffice	Sinh docx/pdf tự động từ kết quả

2. Xây dựng bộ dữ liệu ảnh cây thân gỗ (Nội dung 1)

2.1. Tiêu chí của bộ dữ liệu

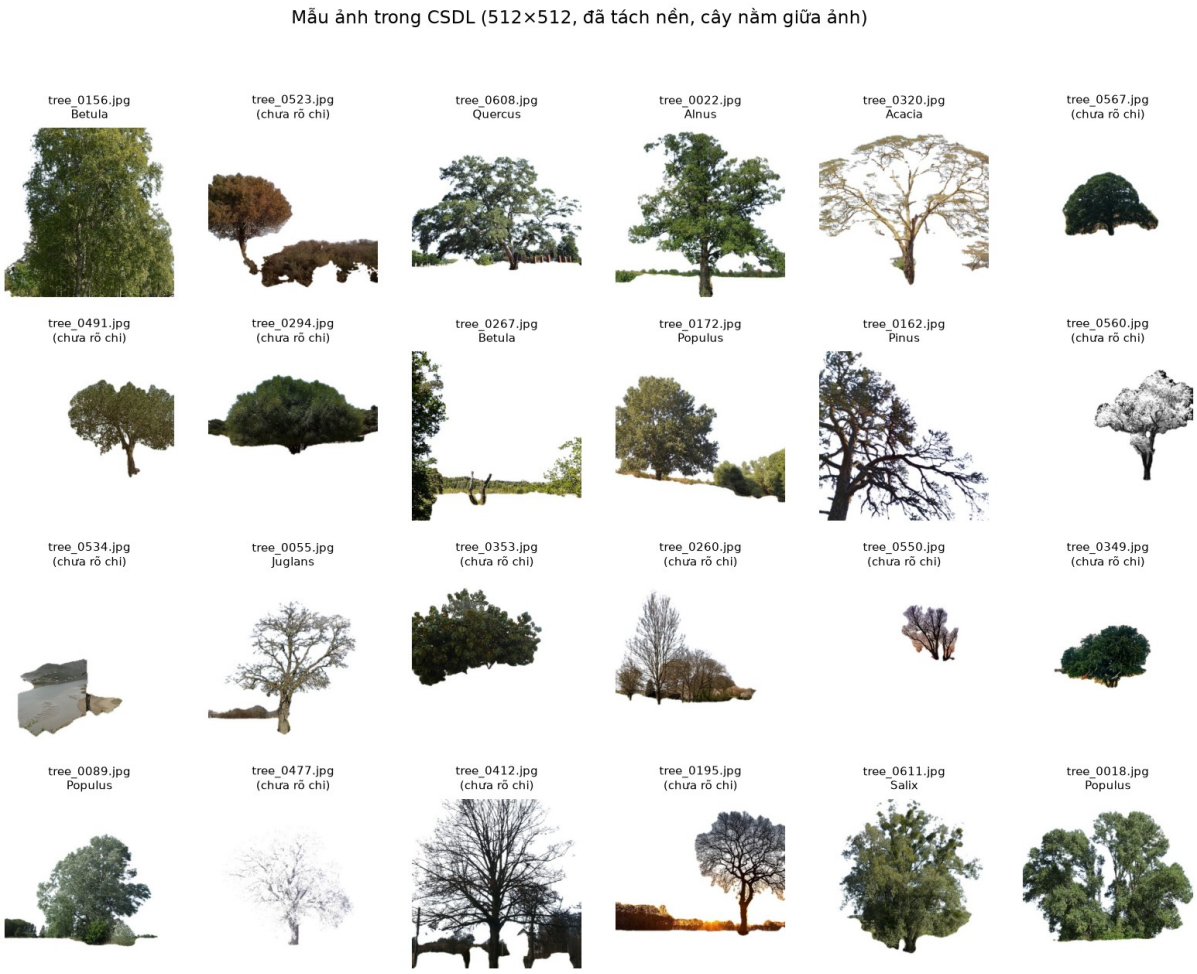
- **Đối tượng:** cây thân gỗ trưởng thành (cây gỗ lớn, cây lá rộng hoặc lá kim), loại trừ cây cọ/dừa (không phải cây thân gỗ thực thụ), cây bụi, cây non và tranh vẽ/ảnh nghệ thuật.
- **Bố cục:** mỗi ảnh chứa đúng một cây hoàn chỉnh (thấy cả thân và toàn bộ tán, tán không bị khung hình cắt), cây là chủ thể chính nằm gần giữa ảnh và đủ lớn (cao ít nhất khoảng 1/4 chiều cao ảnh).
- **Góc chụp:** chụp ngang tầm mắt từ phía bên (không chụp từ trên cao, không ngước từ gốc, không cận cảnh vỏ/lá).
- **Định dạng lưu trữ:** JPEG, 512×512 điểm ảnh, không gian màu RGB 8 bit, chất lượng nén 92; ảnh gốc được thu nhỏ sao cho cạnh ngắn bằng 512 rồi cắt giữa (center-crop) thành hình vuông nên vật thể ở tâm ảnh luôn được giữ nguyên và các ảnh có tỉ lệ khung hình đồng nhất.

- **Tách nền:** ảnh lưu trong CSDL chỉ còn cây trên nền trắng (thư mục data/images_nobg); ảnh chuẩn hoá còn nền (data/images) chỉ là dữ liệu trung gian để tách nền. Ảnh truy vấn được tách nền theo đúng cách đó trước khi so sánh.
- **Siêu dữ liệu đi kèm:** tên file, kích thước, mã băm SHA-1, tiêu đề và đường dẫn nguồn, tác giả, giấy phép, chi (genus) và nhóm hình thái (lá rộng/lá kim) nếu xác định được từ category.

2.2. Nguồn và quy trình sưu tầm

Ảnh được sưu tầm tự động từ kho ảnh mở Wikimedia Commons thông qua MediaWiki API (module src/treedb/collect.py). Điểm xuất phát là các category về "cây mọc đơn lẻ" (Solitary trees) vì đây là những bức ảnh có đúng bố cục một cây hoàn chỉnh giữa khung hình: các category theo loài (Solitary Quercus robur, Solitary Betula pendula, Solitary Pinus sylvestris, Solitary Juglans regia, Solitary Alnus glutinosa, Solitary Populus alba…), category ảnh chất lượng (Quality images of solitary trees), category tổng (Solitary trees) và các category theo quốc gia (Solitary trees by country, duyệt sâu 2 mức). Với mỗi file, hệ thống lấy kích thước gốc, kiểu MIME, tác giả, giấy phép và danh sách category; chi (genus) của cây được nhận diện bằng biểu thức chính quy trên tên category/tiêu đề dựa trên danh mục hơn 80 chi cây thân gỗ phổ biến.

1. Duyệt category → 3523 file ứng viên.
2. Lọc theo quy tắc: MIME là JPEG/PNG; cạnh ngắn ≥ 640 px; tỉ lệ rộng/cao trong [0,65; 1,6]; loại các tiêu đề/category chứa từ khoá không phù hợp (map, diagram, leaf, bark, trunk, detail, flower, aerial, panorama, forest, avenue, bonsai, painting, palm…); loại cây cọ. Kết quả: chấp nhận 2521/3523 file; số file bị loại theo lý do: {'aspect': 326, 'badcat': 340, 'small': 200, 'badword': 102, 'mime': 26, 'palm': 8}.
3. Sắp xếp ưu tiên nguồn "thuần" (category cây đơn lẻ theo loài → ảnh chất lượng → cây đơn lẻ chung/theo quốc gia) và tải tối đa 1 000 ảnh ở độ rộng 1 024 px → 993 ảnh thô.
4. Chuẩn hoá 512×512; khử trùng lặp bằng perceptual hash (DCT 8×8, khoảng cách Hamming ≤ 6).
5. Kiểm duyệt thủ công bằng mắt toàn bộ ảnh trên các bảng ghép 30 ảnh (contact sheet): loại 312 ảnh không đạt tiêu chí bố cục (tán bị cắt, cây quá nhỏ/xa, nhiều cây, cận cảnh, chủ thể là công trình/người, rừng ngập mặn…). Danh sách loại được lưu theo tiêu đề nguồn trong data/manual_exclude.csv để quy trình có thể tái lập.
6. Tách 10 ảnh có nhãn chi làm ảnh truy vấn thử (data/queries, không đưa vào CSDL).
7. Tách nền tự động từng ảnh (chỉ giữ cây, nền thay bằng màu trắng) rồi qua cổng kiểm soát chất lượng: chỉ nhận ảnh tìm thấy cây, có tỉ lệ vùng cây trong [4%, 90%] và tâm vùng cây lệch tâm ảnh không quá 30% mỗi trục → loại thêm 37 ảnh.
8. Kết quả: 627 ảnh đã tách nền trong CSDL (đạt yêu cầu ≥ 500 ảnh).



Hình 1. Một số ảnh trong CSDL sau chuẩn hoá và tách nền (nhãn chi nếu có)

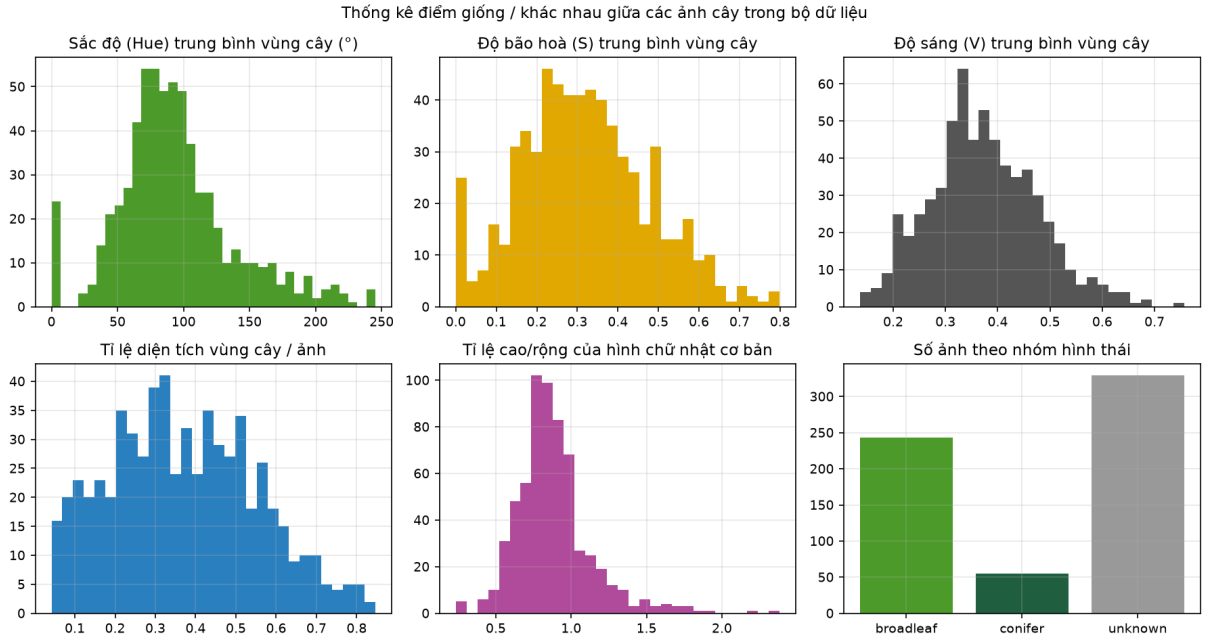
2.3. Thống kê bộ dữ liệu

Bảng 2. Thống kê tổng quan bộ dữ liệu

Chỉ tiêu	Giá trị
Số ảnh trong CSDL	627
Số ảnh truy vấn thử (ngoài CSDL)	10
Kích thước lưu trữ	512×512, JPEG, RGB, đã tách nền (nền trắng)
Dung lượng trung bình / ảnh	61 KB (đã tách nền); 106 KB (trước tách nền)
Kích thước ảnh gốc (rộng × cao)	640–11648 × 640–8736 px
Nhóm hình thái	unknown: 329, broadleaf: 243, conifer: 55
Số ảnh có nhãn chi (genus)	298 (32 chi)
Giấy phép	CC BY-SA 4.0: 259, CC0: 108, CC BY-SA 3.0: 102, CC BY-SA 2.0: 31, CC BY 3.0: 31, CC BY 2.0: 31

Bảng 3. Các chi có nhiều ảnh nhất

Chi (genus)	Số ảnh	Nhóm
Populus	61	lá rộng
Quercus	57	lá rộng
Pinus	46	lá kim
Juglans	33	lá rộng
Betula	25	lá rộng
Alnus	12	lá rộng
Tilia	10	lá rộng
Vachellia	8	lá rộng
Acacia	5	lá rộng
Adansonia	4	lá rộng
Salix	4	lá rộng



Hình 2. Phân bố một số thuộc tính bậc thấp trên toàn bộ dữ liệu: sắc độ, độ bão hoà, độ sáng trung bình của vùng cây; tỉ lệ vùng cây; tỉ lệ cao/rộng; số ảnh theo nhóm

2.4. Đặc điểm giống nhau và khác nhau của các cây trong ảnh

Điểm giống nhau (là cơ sở để các đặc trưng "tìm sự tương đồng" hoạt động):

- Ảnh gốc có bố cục ba tầng thống nhất: phần trên là bầu trời (xanh lam, trắng xám hoặc ánh hoàng hôn), phần giữa là tán cây, phần dưới là mặt đất (cỏ, ruộng, cát, tuyết). Cây

là thành phần liên thông lớn nhất và nằm gần tâm ảnh; vùng cây chiếm trung vị khoảng 35.7% diện tích ảnh. Sau khi tách nền chỉ còn tầng giữa (cây) trên nền trắng.

- Trục chính của vật thể gần như thẳng đứng, thân cây ở dưới nhỏ hơn tán ở trên nên profile bề rộng theo chiều cao có dạng "rộng ở giữa/trên, hẹp ở gốc".
- Màu chủ đạo của vật thể thuộc dải xanh lục – nâu – xám; màu nền thuộc dải xanh lam – trắng (trời) và xanh lục – vàng – nâu (đất). Vì vậy biểu đồ màu toàn ảnh của các ảnh gốc khá giống nhau (nền lấn át màu của cây); đây là lý do ảnh được tách nền trước khi lưu và trích rút đặc trưng.
- Tán cây có kết cấu (texture) không đều, nhiều cạnh nhỏ theo mọi hướng, khác hẳn vùng trời phẳng và vùng đất tương đối mịn.

Điểm khác nhau (là cơ sở để các đặc trưng "tìm sự khác biệt" hoạt động):

- **Loài/chi → hình dạng tán:** sồi (Quercus), óc chó (Juglans) có tán tròn rộng, thân ngắn; dương (Populus), bạch dương (Betula) có tán cao hẹp, thân mảnh; thông (Pinus) có tán không đối xứng, thân lộ dài; keo (Acacia/Vachellia) tán phẳng hình ô. Điều này thể hiện ở tỉ lệ cao/rộng, tâm sai, solidity, moment Hu, lưới 8×8 và profile bề rộng.
- **Mùa và trạng thái lá:** lá xanh mùa hè, vàng/cam mùa thu, trụi lá mùa đông, phủ tuyết/sương giá; sắc độ (H) và độ bão hoà (S) của vùng cây thay đổi mạnh; cây trụi lá có mật độ cạnh và LBP đặc trưng khác cây có lá.
- **Nhóm lá kim / lá rộng:** tán lá kim đậm, xanh sẫm, kết cấu mịn và hình nón/không đối xứng; lá rộng sáng hơn, kết cấu thô, tán tròn.
- **Bối cảnh và ánh sáng:** đồng cỏ, ruộng hoa cải vàng, hoang mạc, tuyết, bờ biển, ngược sáng (silhouette), ảnh đen trắng; sau khi tách nền, bối cảnh chỉ còn ảnh hưởng gián tiếp qua ánh sáng trên tán (độ sáng V, độ tương phản).
- **Khoảng cách chụp:** tỉ lệ vùng cây dao động từ 4.2% đến 84.7%, tức cùng một loài có thể xuất hiện với kích thước khác nhau trong khung; các đặc trưng hình dạng được chuẩn hoá theo hình chữ nhật cơ bản để giảm ảnh hưởng này.

2.5. Định lượng điểm giống và khác nhau theo chi cây

Để kiểm chứng các nhận xét ở trên bằng số liệu, nhóm thống kê trung bình một số thuộc tính bậc thấp trên 244 ảnh có nhãn chi thuộc 7 chi có từ 9 ảnh trở lên. Các thuộc tính này được tính trên mặt nạ vùng cây (trừ khi ghi khác); sắc độ H tính theo độ (0–360°), S và V trong [0, 1].

Bảng 4. Trung bình một số thuộc tính của vùng cây theo chi

Chi	Số ảnh	Diện tích	Cao/rộng	Solidity	Tâm sai	H (°)	S	V	Mật độ cạnh
Alnus	12	0,46	0,91	0,75	0,50	100	0,27	0,41	0,81
Betula	25	0,42	1,00	0,75	0,67	107	0,32	0,44	0,81
Juglans	33	0,42	0,83	0,78	0,65	94	0,35	0,36	0,80

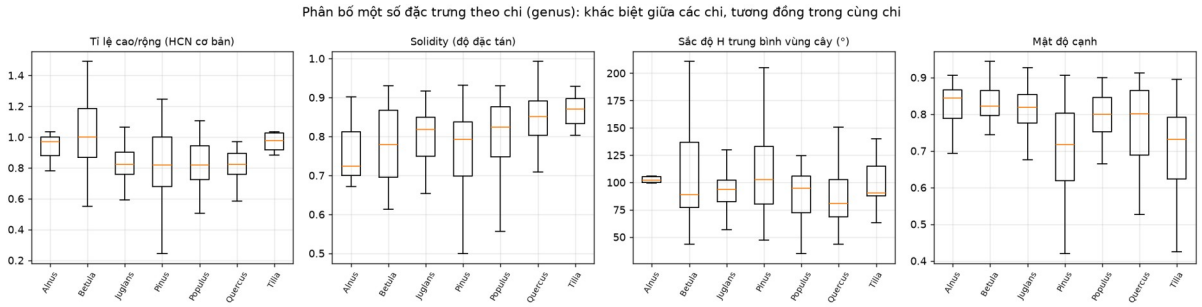
Pinus	46	0,38	0,85	0,76	0,67	112	0,31	0,31	0,71
Populus	61	0,43	0,85	0,80	0,58	90	0,26	0,41	0,79
Quercus	57	0,47	0,82	0,83	0,63	90	0,37	0,37	0,77
Tilia	10	0,57	1,04	0,86	0,55	104	0,33	0,33	0,70
Toàn bộ CSDL	627	0,37	0,88	0,77	0,66	94	0,32	0,37	0,76

- **Khác biệt về dáng:** tỉ lệ cao/rộng trung bình cao nhất ở Tilia (1,04) và thấp nhất ở Quercus (0,82); solidity (độ đặc của tán) cao nhất ở Tilia (0,86), thấp nhất ở Betula (0,75).
- **Khác biệt về màu:** sắc độ trung bình vùng cây dao động từ 90° (Populus) đến 112° (Pinus), tức từ vàng lục (lá vàng, cây trụi lá lộ cành nâu) đến lục lam (lá kim, lá xanh đậm).
- **Giống nhau trong cùng chi nhưng chồng lấn giữa các chi:** độ lệch chuẩn trong từng chi (Hình bên dưới) lớn gần bằng khoảng cách giữa các trung bình, nên không một thuộc tính đơn lẻ nào đủ để phân biệt chi: cần kết hợp nhiều bộ đặc trưng.

Bảng 5. So sánh trung bình giữa nhóm lá rộng và lá kim

Thuộc tính	Lá rộng (n=243)	Lá kim (n=55)
Tỉ lệ diện tích vùng cây	0,442	0,389
Tỉ lệ cao/rộng (HCN cơ bản)	0,871	0,886
Solidity (độ đặc tán)	0,796	0,765
Tâm sai	0,619	0,662
Sắc độ H trung bình vùng cây (°)	90,865	103,729
Độ bão hoà S trung bình	0,319	0,330
Độ sáng V trung bình	0,392	0,321
Mật độ cạnh	0,788	0,719
GLCM contrast (d=1)	0,015	0,012

Lá kim tối hơn (V thấp hơn), tán kém đặc và mật độ cạnh thấp hơn (kết cấu mịn, đều) so với lá rộng; đây là các khác biệt mà bộ đặc trưng màu và kết cấu khai thác.



Hình 3. Phân bố bốn thuộc tính theo chi: hộp = khoảng tứ phân vị, vạch giữa = trung vị

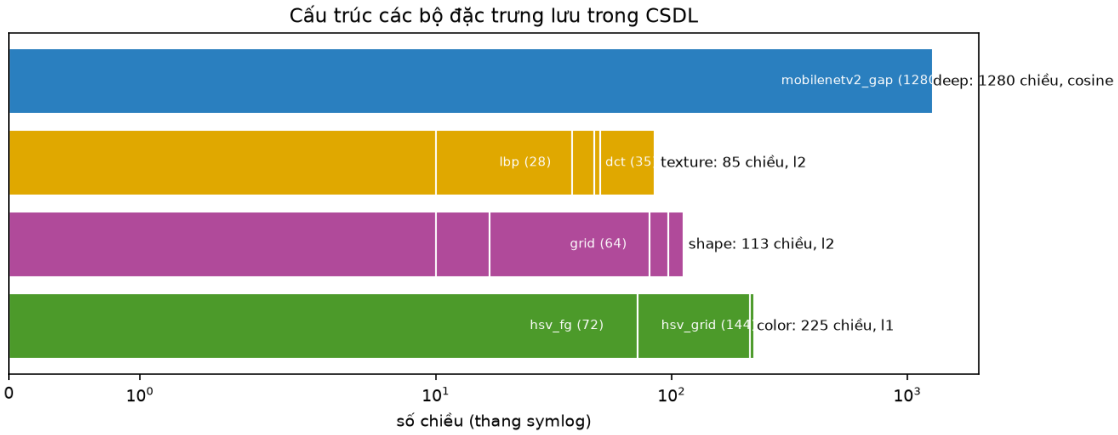
3. Các bộ đặc trưng nhận diện cây (Nội dung 2)

3.1. Định hướng thiết kế

Theo lý thuyết truy vấn ảnh dựa trên nội dung, ảnh được mô tả bằng các thuộc tính bậc thấp: màu sắc của vật thể, hình dạng/kích thước vật thể, và bố cục/kết cấu (độ thô, độ tương phản, hướng sắp xếp của các nét). Mỗi loại thuộc tính bắt được một khía cạnh khác nhau của sự giống/khác, nên hệ thống xây dựng ba bộ đặc trưng thủ công tương ứng và bổ sung một bộ đặc trưng ngữ nghĩa bậc cao (embedding từ mạng nơ-ron tích chập) để thu hẹp "khoảng cách ngữ nghĩa". Các bộ được lưu trữ riêng, có độ đo khoảng cách riêng và được kết hợp theo trọng số khi truy vấn. Mọi đặc trưng đều được tính trên ảnh đã tách nền (cây trên nền trắng): màu và kết cấu chỉ lấy các điểm ảnh cây, hình dạng dùng mặt nạ hình bao của cây, embedding chạy trên toàn ảnh đã tách nền.

Bảng 6. Tổng quan các bộ đặc trưng

Bộ đặc trưng	Số chiều	Độ đo	Trả lời câu hỏi	Tìm tương đồng	Tìm khác biệt
1. Màu sắc	225	L1	Cây có màu gì, phân bố ở đâu trên tán?	Cùng mùa, cùng loại lá	Lá xanh ↔ vàng ↔ trụi lá; lá kim sẫm ↔ lá rộng sáng
2. Hình dạng	113	L2 (z-score)	Tán cây hình gì, thân dài ngắn?	Cùng chi (tán tròn / cao hẹp / hình ô)	Tỉ lệ cao/rộng, tâm sai, độ lõm tán
3. Kết cấu / bố cục	85	L2 (z-score)	Tán mịn hay thô, nét hướng nào?	Lá kim ↔ lá kim; trụi lá ↔ trụi lá	Độ thô, mật độ cạnh, năng lượng DCT
4. Embedding sâu	1280	cosine	Ảnh "trông giống" ảnh nào về ngữ nghĩa?	Khái quát hoá loài, dáng cây	Dáng tán, cấu trúc cành



Hình 4. Cấu trúc các khối trong từng bộ đặc trưng lưu trong CSDL

3.2. Bộ đặc trưng 1 – Màu sắc (225 chiều, độ đo L1)

Không gian màu HSV được chọn thay cho RGB vì H (sắc độ) tách biệt "màu gì" khỏi độ sáng, ít phụ thuộc thiết bị và điều kiện chiếu sáng. Mỗi kênh được lượng tử hoá thành m mức, tổng số ô màu n = 8×3×3 = 72 (H chia mịn hơn vì mang nhiều thông tin nhất). Biểu đồ tần suất H(M) = [h1, …, hn] với hj là số điểm ảnh thuộc ô màu j, được chuẩn hoá L1 (Σhj = 1) để không phụ thuộc số điểm ảnh. Vì ảnh đã tách nền, mọi biểu đồ chỉ đếm các điểm ảnh cây: nếu đếm cả nền trắng thì ô màu trắng sẽ chiếm phần lớn biểu đồ và lấn át màu của cây (hiệu ứng che mặt). Bộ màu gồm 3 khối:

Bảng 7. Các khối của bộ đặc trưng màu sắc

Khối	Chiều	Cách tính	Giá trị thông tin
hsv_fg	72	Biểu đồ HSV 8×3×3 trên các điểm ảnh cây	Màu tổng thể của cây (lá xanh/vàng/nâu, trụi lá, lá kim sẫm) – tìm cây cùng mùa, cùng loại lá
hsv_grid	144	Chia hộp bao của cây thành lưới 3×3, mỗi vùng biểu đồ 4×2×2 = 16 ô (chỉ điểm ảnh cây)	Quan hệ không gian của màu trên cây: ngọn ↔ thân, rìa trái ↔ phải; phân biệt cây cùng tổng màu nhưng bố trí khác (thân nâu lộ dài, tán sáng ở ngọn…)
moments	9	Trung bình, độ lệch chuẩn, độ lệch (skewness) của H, S, V trên vùng cây	Mô tả gọn phân bố màu; bền với nhiễu lượng tử hoá (hai màu gần nhau rơi vào hai ô khác nhau)

Khoảng cách giữa hai biểu đồ dùng L1-norm: d(X, Y) = Σ|xj − yj|, tương đương 2·(1 − giao của hai biểu đồ); giá trị 0 khi hai phân bố màu trùng nhau và tối đa 2 cho mỗi biểu đồ khi không có màu chung.

3.3. Bộ đặc trưng 2 – Hình dạng tán/thân cây (113 chiều, độ đo L2)

Đặc trưng hình dạng được tính trên mặt nạ nhị phân vùng cây của ảnh đã tách nền và được thiết kế để ít phụ thuộc vào vị trí, kích thước và (một phần) góc quay của cây trong ảnh:

Bảng 8. Các khối của bộ đặc trưng hình dạng

Khối	Chiều	Cách tính	Giá trị thông tin
region	10	Diện tích tương đối; tỉ lệ cao/rộng của hình chữ nhật cơ bản; extent (diện tích/hình chữ nhật); solidity (diện tích/bao lồi); tâm sai; độ dài trục chính, trục phụ; hướng trục chính; độ lệch tâm (dx, dy)	Các thước đo hình dạng cơ bản: tán cao hẹp (dương, bạch dương) ↔ tán tròn rộng (sồi); tán đặc ↔ tán thưa/lõm (cây trụi lá có solidity thấp)
hu	7	7 moment bất biến Hu, lấy $-\text{sign}\cdot\log10\lvert\varphi\rvert$	Bất biến với tịnh tiến, tỉ lệ và xoay; mô tả phân bố khối lượng của hình
grid	64	Đặt lưới 8×8 lên hình chữ nhật cơ bản, ô = 1 nếu > 15% diện tích ô là vật thể (chuẩn hoá thước đo về cùng kích thước)	Chuỗi nhị phân mô tả hình thể; so sánh trực tiếp dáng cây: tán tròn, tán hình nón, thân dài ở dưới…
fourier	16	Đường bao ngoài lấy mẫu 128 điểm; biến đổi Fourier; bỏ F0 (tịnh tiến), chia F1 (tỉ lệ), lấy biên độ (bất biến xoay) của 16 hệ số tiếp theo	Mô tả độ gồ ghề/độ đối xứng của đường viền tán ở nhiều tần số
profile	16	Chia hình chữ nhật cơ bản thành 16 dải ngang từ đỉnh xuống gốc, mỗi dải = tỉ lệ bề rộng bị vật thể chiếm	"Chữ ký" dáng cây theo chiều cao: nơi tán rộng nhất, độ dài thân lộ, tán hình ô (rộng trên) hay hình nón (rộng dưới)

Các chiều có thang đo khác nhau nên trước khi tính khoảng cách Euclid (L2) mỗi chiều được chuẩn hoá z-score theo thống kê của CSDL (trung bình, độ lệch chuẩn lưu trong bảng feature_stats).

3.4. Bộ đặc trưng 3 – Kết cấu và bố cục (85 chiều, độ đo L2)

Bảng 9. Các khối của bộ đặc trưng kết cấu / bố cục

Khối	Chiều	Cách tính	Giá trị thông tin
glcm	10	Ma trận đồng xuất hiện mức xám (32 mức, khoảng cách 1 và 3, trung bình 4	Độ thô/mịn và độ tương phản của tán: lá kim mịn đều ↔ lá rộng thô; tán đặc

		hướng) trên vùng bao của cây: contrast, dissimilarity, homogeneity, energy, correlation	↔ tán thưa lộ trời
lbp	28	Biểu đồ Local Binary Pattern đồng nhất (P=8,R=1: 10 ô; P=16,R=2: 18 ô) trên điểm ảnh vùng cây	Mẫu vi kết cấu cục bộ, bất biến với thay đổi độ sáng đơn điệu; phân biệt lá, cành trụi, tuyết phủ
edge	9	Biểu đồ 8 hướng gradient Sobel (trọng số biên độ) + mật độ cạnh	Hướng sắp xếp các nét (cành thẳng đứng của cây trụi lá ↔ tán lá đẳng hướng) và "độ sắc của các nét"
tamura	3	Độ thô (coarseness), độ tương phản (contrast), tính định hướng (directionality)	Ba thuộc tính kết cấu gần với cảm nhận của người
dct	35	Ảnh xám thu về 64×64, biến đổi cosine rời rạc, lấy khối 6×6 tần số thấp bỏ hệ số DC	Bố cục tổng thể (phân bố sáng tối theo vùng lớn), đại diện cho đánh chỉ số trên miền nén (JPEG)

3.5. Bộ đặc trưng 4 (mở rộng) – Embedding sâu MobileNetV2 (1280 chiều, độ đo cosine)

Các thuộc tính bậc thấp không nắm bắt hết ngữ nghĩa ("khoảng cách ngữ nghĩa"). Để bổ sung, hệ thống dùng mạng MobileNetV2 huấn luyện sẵn trên ImageNet (định dạng ONNX, chạy bằng ONNX Runtime trên CPU): ảnh được thu về 224×224, chuẩn hoá theo trung bình/độ lệch chuẩn ImageNet, lấy đầu ra của lớp Global Average Pooling (1280 chiều, trước lớp phân loại) và chuẩn hoá L2. Độ tương đồng cosine giữa hai embedding phản ánh sự giống nhau về hình thái tổng thể mà mạng đã học từ hàng triệu ảnh tự nhiên. Đây là đặc trưng tuỳ chọn: nếu không có model, hệ thống vẫn hoạt động với ba bộ thủ công.

3.6. Đánh giá định lượng giá trị thông tin của các đặc trưng

Giá trị thông tin của một đặc trưng là mức độ nó giúp phân biệt các cây khác loại trong khi vẫn giữ các cây cùng loại ở gần nhau. Nhóm đo bằng ba chỉ số trên các ảnh có nhãn chi, mỗi khối dùng đúng độ đo khoảng cách của bộ chứa nó:

- **Tỉ số Fisher:** trung bình theo từng chiều (đã chuẩn hoá z-score) của tỉ số phương sai giữa các chi / phương sai trong cùng chi. Càng lớn, chiều đó càng tách các chi.

- **Tỉ số tách:** khoảng cách trung bình giữa hai ảnh khác chi chia cho khoảng cách trung bình giữa hai ảnh cùng chi. Lớn hơn 1 nghĩa là đặc trưng đặt ảnh cùng chi gần nhau hơn.
- **Độ chính xác 1-NN:** tỉ lệ ảnh mà ảnh gần nhất (bỏ chính nó) có cùng chi. Mức ngẫu nhiên (hoán vị nhãn) là 0,186.

Bảng 10. Giá trị thông tin của từng khối đặc trưng (xếp theo độ chính xác 1-NN)

Bộ	Khối	Chiều	Độ đo	Fisher	Tỉ số tách	1-NN
Embedding sâu	mobilenetv2_gap (MobileNetV2 GAP)	1280	COSINE	0,071	1,068	0,561
Màu sắc	hsv_grid (biểu đồ HSV theo lưới 3×3)	144	L1	0,064	1,041	0,545
Kết cấu / bố cục	lbp (LBP)	28	L2	0,151	1,130	0,508
Màu sắc	hsv_fg (biểu đồ HSV vùng cây)	72	L1	0,049	1,035	0,480
Màu sắc	moments (moment màu)	9	L1	0,097	1,061	0,393
Kết cấu / bố cục	glcm (GLCM)	10	L2	0,124	1,079	0,328
Kết cấu / bố cục	dct (DCT tần số thấp)	35	L2	0,049	1,013	0,328
Kết cấu / bố cục	edge (hướng cạnh + mật độ cạnh)	9	L2	0,330	1,172	0,316
Hình dạng	grid (lưới nhị phân 8×8)	64	L2	0,058	1,028	0,295
Hình dạng	profile (profile bề rộng)	16	L2	0,102	1,058	0,295
Kết cấu / bố cục	tamura (Tamura)	3	L2	0,145	1,099	0,287
Hình dạng	region (thước đo vùng)	10	L2	0,088	1,061	0,275
Hình dạng	fourier (hệ số Fourier đường bao)	16	L2	0,084	1,099	0,262
Hình dạng	hu (moment Hu)	7	L2	0,077	1,060	0,258

Bảng 11. Giá trị thông tin của cả bộ đặc trưng

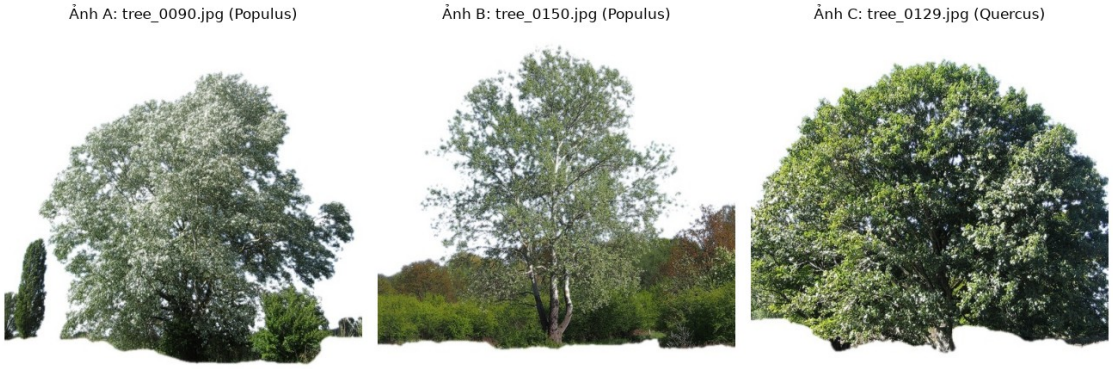
Bộ đặc trưng	Chiều	Fisher	Tỉ số tách	1-NN
Màu sắc	225	0,061	1,043	0,570
Hình dạng	113	0,072	1,045	0,307
Kết cấu / bố cục	85	0,124	1,068	0,463
Embedding sâu	1280	0,071	1,068	0,561

Nhận xét:

- Mọi bộ đặc trưng đều có tỉ số tách > 1 và 1-NN cao hơn mức ngẫu nhiên (0,186), tức đều mang thông tin về loài cây. Khối có 1-NN cao nhất là mobilenetv2_gap (embedding sâu, 0,561), gấp 3,0 lần ngẫu nhiên.
- Khối có tỉ số Fisher lớn nhất là edge (0,330): ít chiều nhưng mỗi chiều tách chi tốt, nên là đặc trưng "tìm sự khác biệt" rất hiệu quả trên mỗi chiều lưu trữ.
- Sau khi tách nền, các khối màu chỉ mô tả chính cây; khối hsv_grid (màu theo vị trí trên tán) mang nhiều thông tin hơn hsv_fg vì phân biệt được cả cách bố trí màu (thân lộ, ngọn sáng) chứ không chỉ tổng màu.
- Các khối hình dạng có 1-NN thấp hơn khi dùng riêng vì cùng một chi có nhiều dáng (tuổi cây, cắt tỉa, gió) và hình bao chỉ là hình chiếu 2D; chúng vẫn bổ sung thông tin độc lập với màu (không phụ thuộc mùa, ánh sáng) nên được giữ trong tổ hợp có trọng số. Các khối có tỉ số tách gần 1 (grid, dct) mang ít thông tin về chi và chủ yếu giúp tìm ảnh cùng bối cảnh/bố cục.

3.7. Ví dụ minh hoạ: đặc trưng tìm sự tương đồng và sự khác biệt

Chọn ba ảnh trong CSDL: A và B cùng chi Populus (hai cây khác nhau, khác tác giả; B là ảnh cùng chi có hình dạng gần A nhất), C thuộc chi Quercus (ảnh tiêu biểu nhất của chi theo hình dạng). Bảng dưới liệt kê giá trị một số đặc trưng và khoảng cách giữa từng cặp theo mỗi bộ đặc trưng.



Hình 5. Ba ảnh minh hoạ: A, B (Populus) và C (Quercus)

Bảng 12. Giá trị đặc trưng của ba ảnh minh hoạ

Đặc trưng	Ảnh A	Ảnh B	Ảnh C
Tỉ lệ diện tích vùng cây	0,541	0,590	0,656
Tỉ lệ cao/rộng (HCN cơ bản)	0,820	0,852	0,820
Solidity (độ đặc tán)	0,876	0,892	0,945
Tâm sai	0,439	0,440	0,638
Sắc độ H trung bình vùng cây (°)	109,7	97,1	109,4
Độ bão hoà S trung bình	0,222	0,306	0,330
Độ sáng V trung bình	0,417	0,421	0,361
Mật độ cạnh	0,852	0,779	0,818
GLCM contrast (d=1)	0,016	0,012	0,032

Bảng 13. Khoảng cách giữa các cặp ảnh theo từng bộ đặc trưng

Bộ đặc trưng	Độ đo	d(A,B)	d(A,C)	d(B,C)	A–B gần nhất?
Màu sắc	L1	8,841	9,207	11,977	đúng
Hình dạng	L2	5,427	6,726	8,018	đúng
Kết cấu / bố cục	L2	7,543	9,384	9,070	đúng
Embedding sâu	COSINE	0,215	0,147	0,300	không

Theo các bộ màu sắc, hình dạng, kết cấu / bố cục, hai cây cùng chi A–B gần nhau hơn so với cây khác chi C: các đặc trưng này vừa giúp tìm sự tương đồng (A–B nhỏ) vừa tìm sự khác biệt (A–C, B–C lớn). Riêng bộ embedding sâu cho kết quả ngược lại ở ví dụ này, minh hoạ rằng không bộ đặc trưng nào đúng trong mọi trường hợp và vì sao hệ thống kết hợp nhiều bộ theo trọng số.

4. Trích rút đặc trưng và hệ CSDL quản trị đặc trưng (Nội dung 3)

4.1. Quy trình trích rút

Script scripts/extract_features.py duyệt toàn bộ ảnh trong data/manifest.csv; với mỗi ảnh: đọc và chuẩn hoá (giống hệt cách áp dụng cho ảnh truy vấn) → tách nền và lưu ảnh vào data/images_nobg → tính ba bộ đặc trưng thủ công (chạy song song nhiều tiến trình) → tính embedding theo lô 32 ảnh → ghi vào SQLite → tính thống kê chuẩn hoá cho từng bộ. Thời gian trích rút trung bình khoảng 0,1 giây/ảnh cho ba bộ thủ công (đã song song hoá) và 0,02 giây/ảnh cho embedding.

4.2. Ảnh tách nền

Mọi ảnh được tách nền tự động trước khi đưa vào CSDL: chỉ giữ lại cây, phần nền được thay bằng màu trắng. Ảnh truy vấn cũng được tách nền theo cùng cách trước khi trích rút đặc trưng.



Hình 6. Ảnh chuẩn hoá (trên), vùng cây (giữa) và ảnh đã tách nền dùng làm dữ liệu (dưới)

4.3. Lược đồ CSDL đặc trưng (SQLite)

Hệ CSDL theo mô hình lai: siêu dữ liệu quan hệ của ảnh lưu trong bảng thông thường để lọc chính xác (theo chi, giấy phép, kích thước…), còn vector đặc trưng lưu dạng BLOB float32 gắn với khoá (ảnh, bộ đặc trưng); chỉ mục được xây trên đặc trưng chứ không trên dữ liệu ảnh gốc, do đó có thể cập nhật pipeline đặc trưng mà không mất ảnh. Module src/treedb/db.py cài đặt toàn bộ thao tác.

Bảng 14. Lược đồ CSDL đặc trưng

Bảng	Cột chính	Vai trò
images	image_id (PK), filename (UNIQUE), path, width, height, format, file_size, sha1, source_title, source_url, author, license, genus, group_label, orig_width, orig_height, fg_coverage, ingested_at	Siêu dữ liệu mô tả từng ảnh (thông tin ngoài lề + nhãn)
feature_sets	set_name (PK), dim, description, extractor_version, metric, layout_json	Danh mục bộ đặc trưng: số chiều, độ đo, bố cục các khối (để giải thích kết quả trung gian)

features	image_id (FK), set_name (FK), dim, vector BLOB; PK(image_id, set_name)	Vector đặc trưng float32 của mỗi ảnh theo từng bộ
feature_stats	set_name, key (mean/std/scale), value BLOB	Thống kê chuẩn hoá: z-score theo chiều và hệ số scale để kết hợp các bộ
indexes	name (PK), kind, meta_json, payload BLOB, built_at	Chỉ mục đa chiều: PCA + toạ độ cho cây k-d; tâm cụm K-means
image_clusters	index_name, image_id, cluster_id	Ảnh thuộc cụm nào (truy vấn theo phân cụm)
query_log	query_id, query_path, backend, weights_json, top_k, results_json, elapsed_ms, created_at	Nhật ký truy vấn (phục vụ đánh giá và phản hồi)

Bảng 15. Nội dung bảng feature_sets sau khi trích rút

Bộ	Chiều	Độ đo	Số vector	Bố cục khối
color	225	l1	627	hsv_fg(72), hsv_grid(144), moments(9)
shape	113	l2	627	region(10), hu(7), grid(64), fourier(16), profile(16)
texture	85	l2	627	glcm(10), lbp(28), edge(9), tamura(3), dct(35)
deep	1280	cosine	627	mobilenetv2_gap(1280)

CSDL hiện có 627 ảnh, 2508 vector đặc trưng thuộc 4 bộ, dung lượng file SQLite 5.4 MB.

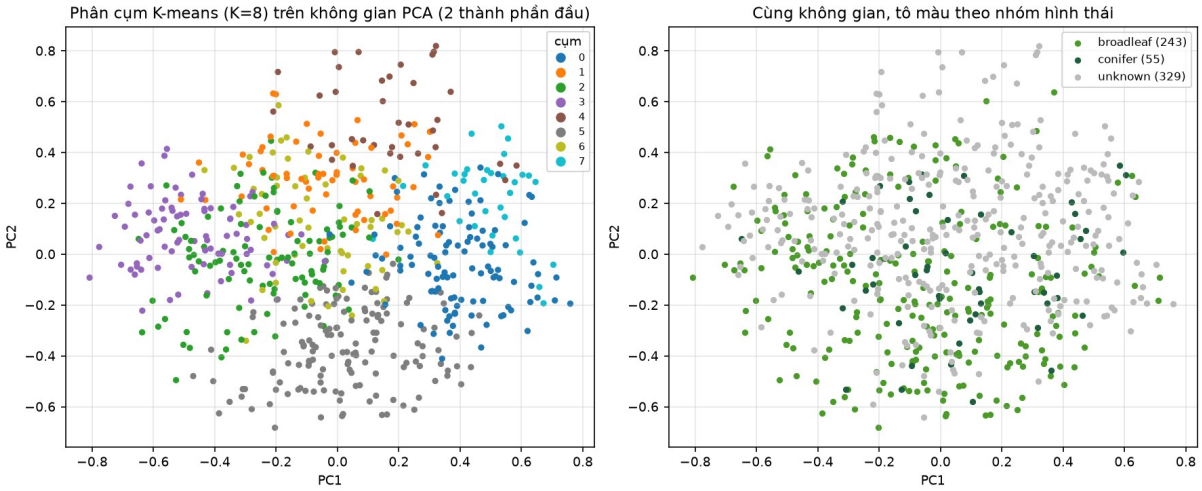
4.4. Chuẩn hoá và kết hợp các bộ đặc trưng

Các bộ có số chiều và thang đo khác nhau nên không thể cộng khoảng cách trực tiếp. Với mỗi bộ s, hệ thống lưu: mean và std theo chiều (dùng cho z-score ở các bộ dùng L2) và scale_s = khoảng cách trung bình giữa hai ảnh ngẫu nhiên trong CSDL (ước lượng trên 4 000 cặp). Khoảng cách chuẩn hoá $\tilde{d}_s = d_s/scale_s$ có kỳ vọng ≈ 1 với cặp ảnh ngẫu nhiên, nên có thể kết hợp tuyến tính: $D = \Sigma_s w_s \cdot \tilde{d}_s$ với $\Sigma w_s = 1$. Độ tương đồng hiển thị cho người dùng là $sim = 1/(1 + D) \in (0, 1]$. Trọng số mặc định: color = 0.3, shape = 0.25, texture = 0.2, deep = 0.25 (có thể đổi khi truy vấn).

4.5. Cấu trúc chỉ mục đa chiều

Để tránh quét tuyến tính toàn bộ CSDL khi kích thước tăng, hệ thống xây dựng hai cấu trúc chỉ mục trên không gian nhúng chung E (nối các vector đã chuẩn hoá của mọi bộ, nhân √w_s/scale_s để khoảng cách Euclid trong E xấp xỉ D):

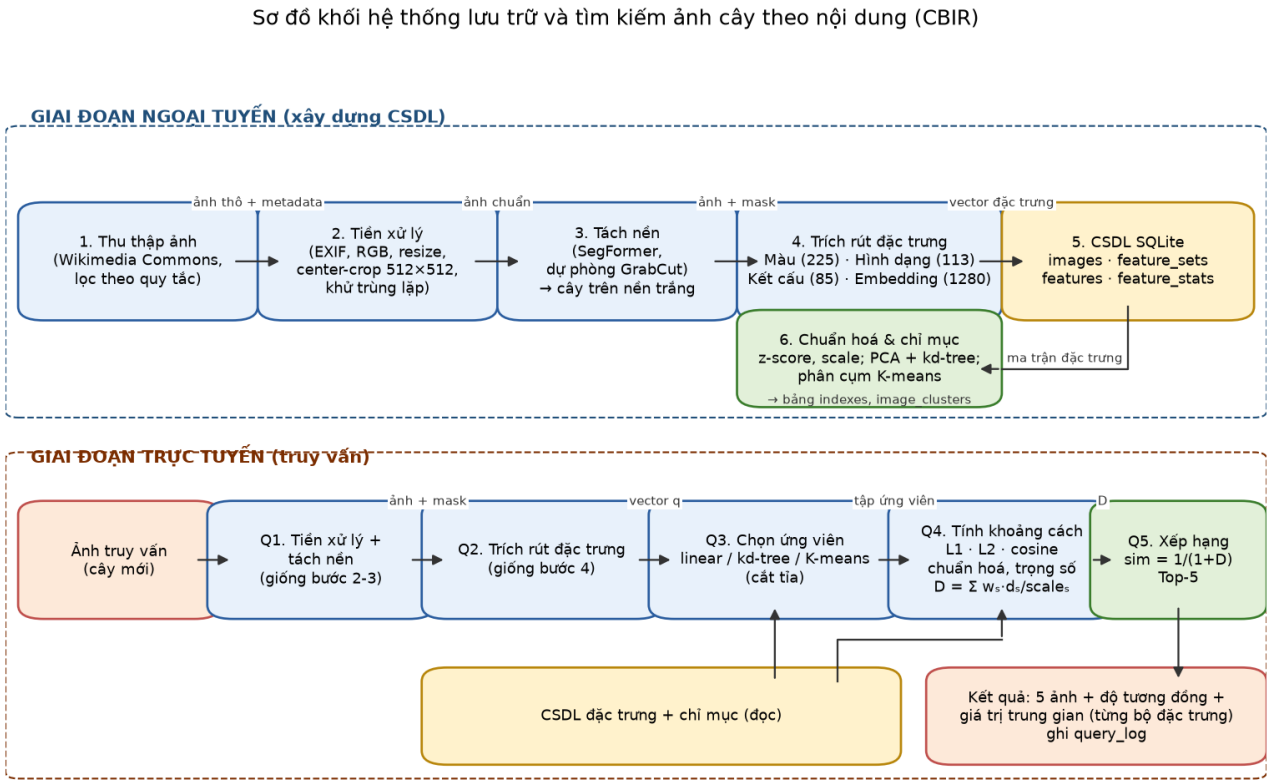
- **Cây k-d trên không gian PCA:** giảm E (1703 chiều) xuống 32 thành phần chính (giữ 62.8% phương sai) rồi dựng cây k-d (SciPy cKDTree). Khi truy vấn, lấy 60 láng giềng gần nhất trong cây làm tập ứng viên, sau đó xếp hạng lại bằng khoảng cách chính xác D (lọc – tinh chỉnh).
- **Phân cụm K-means (K = 8):** cài đặt thuật toán Lloyd với khởi tạo k-means++ bằng NumPy; kích thước các cụm: [106, 62, 103, 81, 38, 144, 59, 34]. Khi truy vấn, tính khoảng cách từ vector truy vấn đến các tâm cụm, quét các ảnh trong ≥ 2 cụm gần nhất (mở rộng cho tới khi đủ ứng viên) rồi xếp hạng chính xác.



Hình 7. Phân bố ảnh trong không gian PCA: theo cụm K-means (trái) và theo nhóm hình thái (phải)

5. Hệ thống tìm kiếm ảnh tương đồng (Nội dung 4)

5.1. Sơ đồ khối, chức năng và dữ liệu vào/ra của từng khối



Hình 8. Sơ đồ khối hệ thống: giai đoạn ngoại tuyến (trên) và trực tuyến (dưới)

Bảng 16. Chức năng và dữ liệu vào/ra của từng khối

Khối	Chức năng	Dữ liệu vào	Dữ liệu ra
1. Thu thập ảnh	Duyệt category Commons, lọc theo quy tắc, tải ảnh, ghi siêu dữ liệu	Danh sách category gốc	Ảnh thô (JPEG) + raw_manifest.csv (nguồn, tác giả, giấy phép, chi)
2. Tiền xử lý	Xoay EXIF, RGB, resize cạnh ngắn 512, center-crop, khử trùng lặp pHash, áp dụng danh sách kiểm duyệt, tách ảnh truy vấn thử	Ảnh thô	Ảnh 512×512 + manifest.csv, queries.csv
3. Tách nền	Tách nền tự động: chỉ giữ cây, nền thay bằng màu trắng	Ảnh RGB 512×512	Ảnh chỉ còn cây trên nền trắng (lưu vào CSDL), mặt nạ hình bao, tỉ lệ vùng cây, độ lệch tâm
4. Trích rút đặc trưng	Tính 4 bộ đặc trưng	Ảnh đã tách nền + mặt nạ	4 vector: color (225), shape (113), texture (85), deep (1280) + bố cục khối
5. CSDL SQLite	Lưu siêu dữ liệu và vector; CRUD; thống kê	Bản ghi ảnh + vector	Bảng images, feature_sets, features
6. Chuẩn hoá & chỉ mục	mean/std/scale từng bộ; PCA	Ma trận đặc trưng	feature_stats, indexes,

	+ cây k-d; K-means		image_clusters
Q1. Tiền xử lý + tách nền truy vấn	Như khối 2–3 cho ảnh mới (mọi kích thước)	Ảnh truy vấn	Ảnh 512×512 đã tách nền + mặt nạ
Q2. Trích rút đặc trưng truy vấn	Như khối 4	Ảnh + mặt nạ	Vector q của từng bộ
Q3. Chọn ứng viên	linear: toàn bộ; kdtree: 60 láng giềng PCA; kmeans: ≥ 2 cụm gần nhất	q, chỉ mục	Tập ứng viên (chỉ số ảnh)
Q4. Tính khoảng cách	d_s theo độ đo từng bộ; chuẩn hoá d_s/scale_s; D = Σ w_s·d̃_s	q, vector ứng viên, thống kê, trọng số	d_s, d̃_s, đóng góp w_s·d̃_s, D cho mỗi ứng viên
Q5. Xếp hạng	sim = 1/(1+D); sắp giảm dần; lấy top-K; ghi query_log	D của các ứng viên	5 ảnh giống nhất + độ tương đồng + bảng giá trị trung gian

Quy trình thực hiện một truy vấn

1. Người dùng cung cấp ảnh cây mới (tải lên trên giao diện web hoặc đường dẫn trên dòng lệnh) và chọn backend, số kết quả K (mặc định 5), trọng số các bộ.
2. Ảnh được chuẩn hoá về 512×512 đúng như ảnh CSDL (nếu ảnh không vuông sẽ được cắt giữa), rồi tách nền giống hệt ảnh CSDL (cây trên nền trắng, kèm mặt nạ vùng cây).
3. Trích rút 4 vector đặc trưng bằng chính các hàm đã dùng khi xây CSDL (đảm bảo cùng cách thức).
4. Nạp ma trận đặc trưng và thống kê chuẩn hoá từ SQLite (một lần khi khởi động), chọn tập ứng viên theo backend.
5. Với mỗi ứng viên tính khoảng cách từng bộ (L1/L2/cosine), chuẩn hoá theo scale, kết hợp theo trọng số thành D và độ tương đồng sim.
6. Sắp xếp giảm dần theo sim, trả về 5 ảnh đầu cùng bảng giá trị trung gian; ghi nhật ký truy vấn.

5.2. Minh hoạ kết quả trung gian của quá trình truy vấn

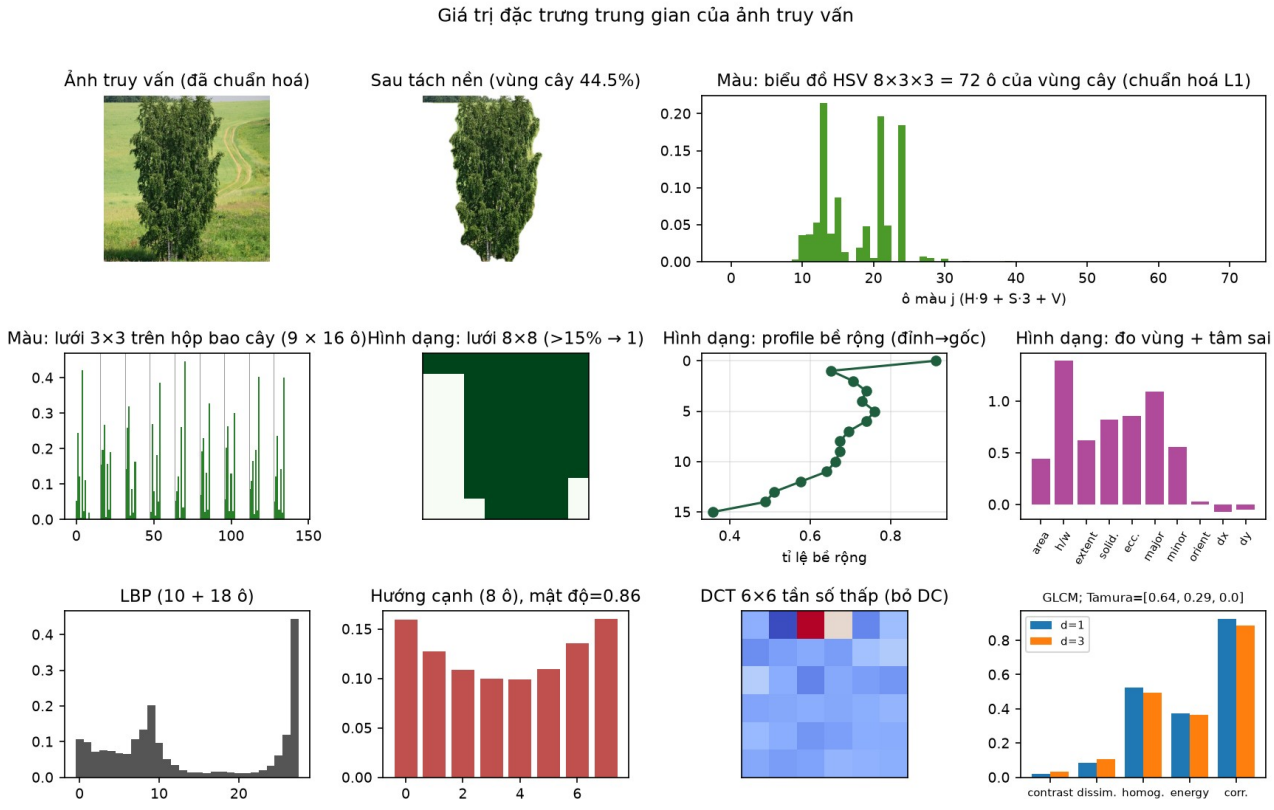
Ví dụ 1: ảnh truy vấn query_01.jpg (chi thật: Betula), backend linear

Ảnh truy vấn không nằm trong CSDL. Tỉ lệ vùng cây sau phân đoạn: 44.5%. Một số giá trị đặc trưng đã trích rút (làm tròn 4 chữ số):

Bảng 17. Giá trị đặc trưng của ảnh truy vấn query_01.jpg

Đặc trưng (khối)	Giá trị
Màu: hsv_fg (12 ô đầu / 72)	0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.003, 0.036, 0.037
Màu: hsv_grid (12 ô đầu / 144)	0.053, 0.244, 0.122, 0.005, 0.421, 0.024, 0.111, 0.000, 0.019, 0.000, 0.002, 0.000
Màu: moments (mean H,S,V; std H,S,V; skew H,S,V)	0.258, 0.557, 0.343, 0.044, 0.228, 0.194, 0.946, 0.417, 0.632

Hình dạng: region (area, h/w, extent, solidity, ecc, major, minor, orient, dx, dy)	0.445, 1.391, 0.619, 0.823, 0.858, 1.091, 0.560, 0.031, -0.071, -0.049
Hình dạng: hu (7 moment, log)	0.68, 1.82, 3.13, 4.44, -8.32, -5.72, -8.45
Hình dạng: grid 8×8 (64 bit, đọc trái→phải, trên→dưới)	1111111100111111001111110011111100111111001111110011111000011110
Hình dạng: profile (16 dải, đỉnh→gốc)	0.91, 0.65, 0.71, 0.74, 0.73, 0.76, 0.74, 0.70, 0.67, 0.67, 0.66, 0.64, 0.58, 0.51, 0.49, 0.36
Kết cấu: glcm (contrast, dissim, homog, energy, corr × d=1,3)	0.021, 0.031, 0.085, 0.106, 0.525, 0.494, 0.372, 0.366, 0.925, 0.888
Kết cấu: edge (8 hướng + mật độ)	0.159, 0.128, 0.109, 0.100, 0.099, 0.109, 0.136, 0.160, 0.864
Kết cấu: tamura (coarseness, contrast, directionality)	0.635, 0.288, 0.003
Embedding: 10 chiều đầu / 1280 (chuẩn hoá L2)	0.0138, 0.0003, 0.0247, 0.0100, 0.0022, 0.0099, 0.0638, 0.0018, 0.0005, 0.0417



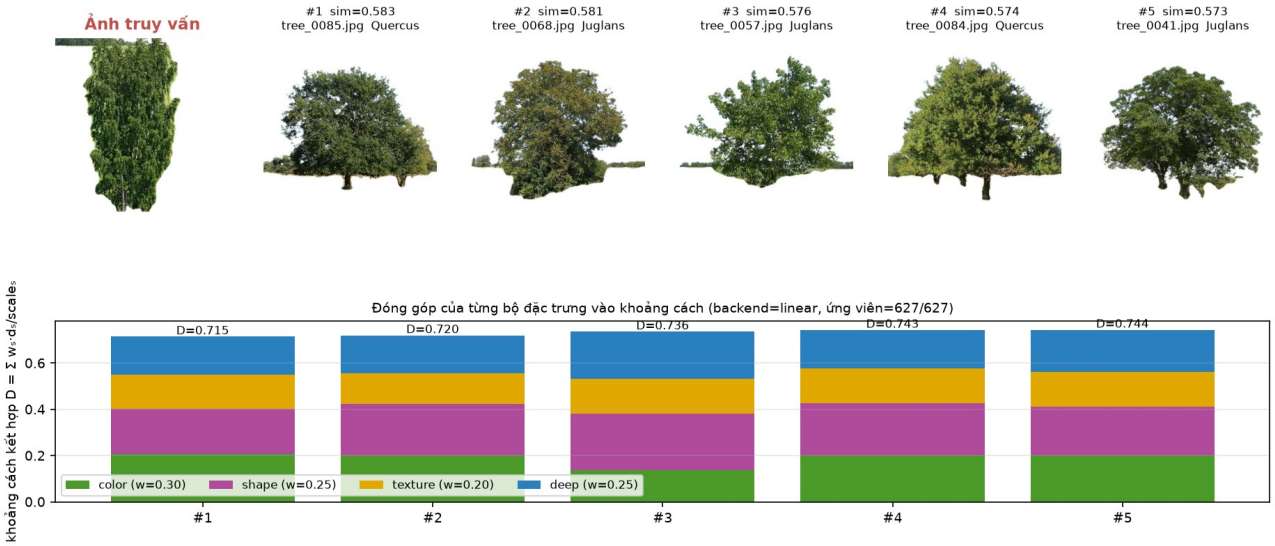
Hình 9. Biểu diễn trực quan các đặc trưng của ảnh truy vấn query_01.jpg

Bảng 18. Khoảng cách chuẩn hoá từng bộ, khoảng cách kết hợp và độ tương đồng của top-5 (trọng số: color=0.30, shape=0.25, texture=0.20, deep=0.25)

Hạng	Ảnh	Chi	d̃ color	d̃ shape	d̃ texture	d̃ deep	D	sim
1	tree_0085.	Quercus	0.688	0.787	0.739	0.655	0.715	0.583

	jpg							
2	tree_0068.jpg	Juglans	0.671	0.894	0.653	0.660	0.720	0.581
3	tree_0057.jpg	Juglans	0.463	0.968	0.756	0.816	0.736	0.576
4	tree_0084.jpg	Quercus	0.667	0.912	0.740	0.669	0.743	0.574
5	tree_0041.jpg	Juglans	0.669	0.846	0.744	0.731	0.744	0.573

Khoảng cách thô (raw) tương ứng của hạng 1: color = 9.7268, shape = 11.3353, texture = 9.3788, deep = 0.1877; sau khi chia cho scale từng bộ và nhân trọng số, tổng D = 0.715 → sim = 1/(1+D) = 0.583.



Hình 10. Kết quả top-5 cho ảnh query_01.jpg và đóng góp của từng bộ đặc trưng vào khoảng cách kết hợp

Thời gian xử lý (ms): load_normalize = 4.7, remove_background = 286.1, extract_color = 21.3, extract_shape = 75.1, extract_texture = 92.2, extract_deep = 46.1, candidates = 0.0, distance_rank = 5.7, total = 532.0.

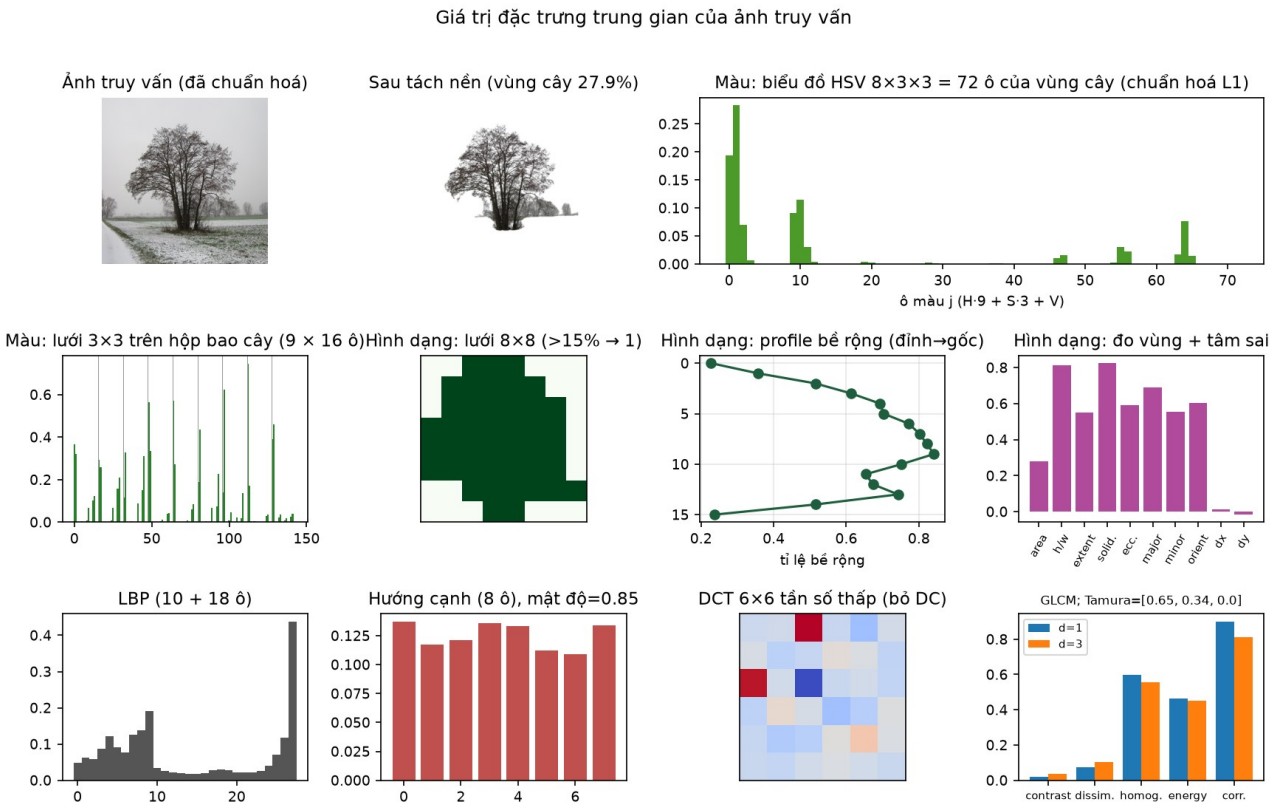
Ví dụ 2: ảnh truy vấn query_02.jpg (chi thật: Alnus), backend linear

Ảnh truy vấn không nằm trong CSDL. Tỉ lệ vùng cây sau phân đoạn: 27.9%. Một số giá trị đặc trưng đã trích rút (làm tròn 4 chữ số):

Bảng 19. Giá trị đặc trưng của ảnh truy vấn query_02.jpg

Đặc trưng (khối)	Giá trị
Màu: hsv_fg (12 ô đầu / 72)	0.194, 0.283, 0.070, 0.007, 0.000, 0.000, 0.000, 0.000, 0.000, 0.092, 0.115, 0.031

Màu: hsv_grid (12 ô đầu / 144)	0.368, 0.320, 0.001, 0.000, 0.002, 0.006, 0.000, 0.000, 0.008, 0.069, 0.000, 0.000
Màu: moments (mean H,S,V; std H,S,V; skew H,S,V)	0.242, 0.072, 0.448, 0.310, 0.083, 0.203, 0.906, 0.980, -0.034
Hình dạng: region (area, h/w, extent, solidity, ecc, major, minor, orient, dx, dy)	0.279, 0.812, 0.552, 0.824, 0.593, 0.691, 0.556, 0.602, 0.011, -0.016
Hình dạng: hu (7 moment, log)	0.75, 2.85, 3.78, 4.69, 9.07, 6.21, -9.08
Hình dạng: grid 8×8 (64 bit, đọc trái→phải, trên→dưới)	0011100001111100011111101111111011111110111111100 011111100011000
Hình dạng: profile (16 dải, đỉnh→gốc)	0.23, 0.36, 0.51, 0.61, 0.69, 0.70, 0.77, 0.80, 0.82, 0.84, 0.75, 0.65, 0.67, 0.74, 0.51, 0.24
Kết cấu: glcm (contrast, dissim, homog, energy, corr × d=1,3)	0.018, 0.035, 0.073, 0.104, 0.598, 0.555, 0.464, 0.450, 0.899, 0.811
Kết cấu: edge (8 hướng + mật độ)	0.137, 0.117, 0.121, 0.136, 0.133, 0.112, 0.109, 0.134, 0.855
Kết cấu: tamura (coarseness, contrast, directionality)	0.650, 0.343, 0.001
Embedding: 10 chiều đầu / 1280 (chuẩn hoá L2)	0.0061, 0.0090, 0.0123, 0.0406, 0.0014, 0.0009, 0.0278, 0.0002, 0.0374, 0.0242



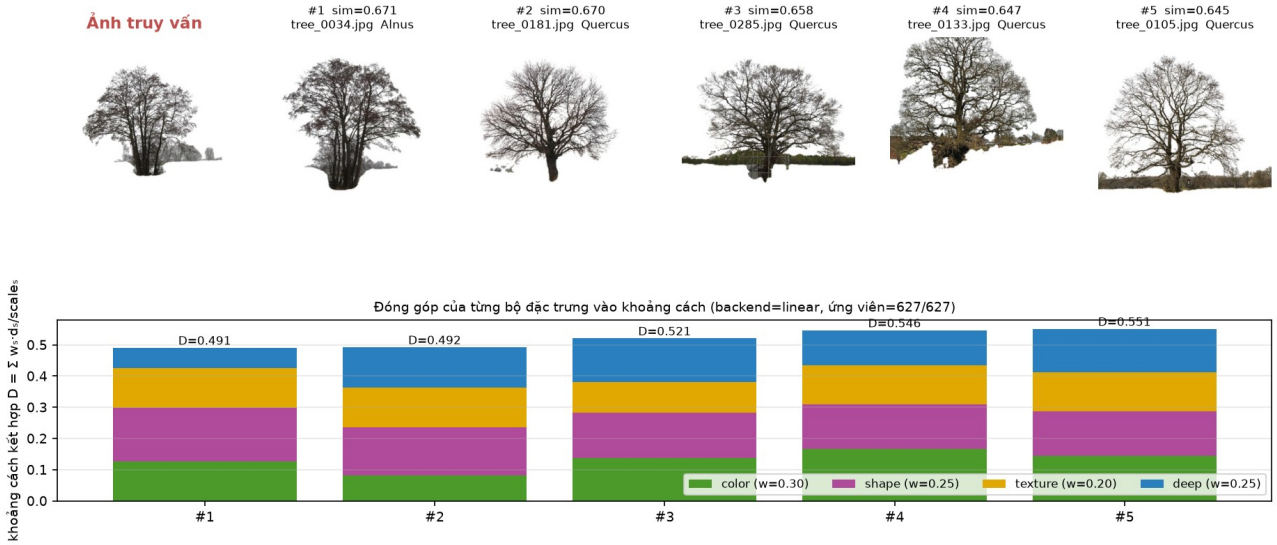
Hình 11. Biểu diễn trực quan các đặc trưng của ảnh truy vấn query_02.jpg

Bảng 20. Khoảng cách chuẩn hoá từng bộ, khoảng cách kết hợp và độ tương đồng của top-5 (trọng số: color=0.30, shape=0.25, texture=0.20, deep=0.25)

Hạng	Ảnh	Chi	d̃ color	d̃ shape	d̃ texture	d̃ deep	D	sim

1	tree_0034.jpg	Alnus	0.425	0.684	0.632	0.264	0.491	0.671
2	tree_0181.jpg	Quercus	0.274	0.615	0.634	0.519	0.492	0.670
3	tree_0285.jpg	Quercus	0.459	0.583	0.490	0.557	0.521	0.658
4	tree_0133.jpg	Quercus	0.558	0.565	0.631	0.446	0.546	0.647
5	tree_0105.jpg	Quercus	0.481	0.568	0.632	0.554	0.551	0.645

Khoảng cách thô (raw) tương ứng của hạng 1: color = 6.0082, shape = 9.8536, texture = 8.0191, deep = 0.0756; sau khi chia cho scale từng bộ và nhân trọng số, tổng D = 0.491 → sim = 1/(1+D) = 0.671.



Hình 12. Kết quả top-5 cho ảnh query_02.jpg và đóng góp của từng bộ đặc trưng vào khoảng cách kết hợp

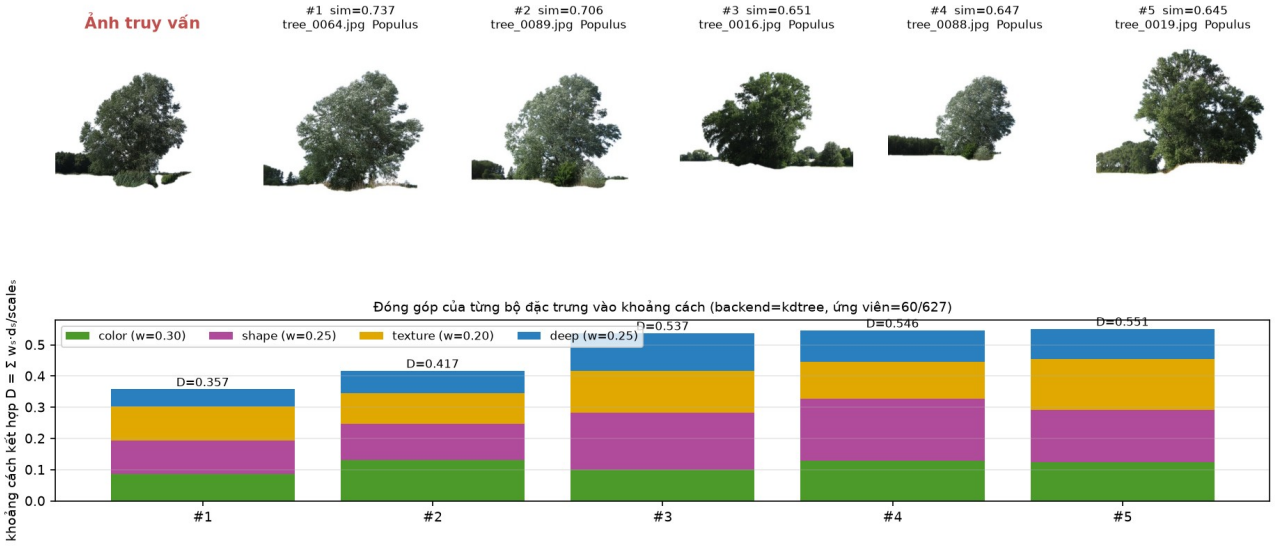
Thời gian xử lý (ms): load_normalize = 3.4, remove_background = 273.1, extract_color = 10.2, extract_shape = 25.9, extract_texture = 77.1, extract_deep = 4.5, candidates = 0.0, distance_rank = 4.6, total = 399.6.

Ví dụ 3: ảnh query_03.jpg (chi thật: Populus) với backend kdtree

Cây k-d trên 32 thành phần PCA trả về 60 ứng viên trong 2.02 ms (khoảng cách trong không gian PCA của 5 ứng viên đầu: 0.425, 0.432, 0.528, 0.531, 0.581); các ứng viên được xếp hạng lại bằng D.

```
Anh truy van: C:\Projects\MyProject\CSDL-DPT\data\queries\query_03.jpg  (ti le vung cay: 30.81%)
Backend: kdtree  | ung vien: 60/627  | trong so: color=0.30, shape=0.25, texture=0.20, deep=0.25
  dac trung [color] dim=225: hsv_fg(72), hsv_grid(144), moments(9)
  dac trung [shape] dim=113: region(10), hu(7), grid(64), fourier(16), profile(16)
```

```
 dac trung [texture] dim=85: glcm(10), lbp(28), edge(9), tamura(3), dct(35)
 dac trung [deep] dim=1280: mobilenetv2_gap(1280)
# anh            chi             sim       D |     color     shape   texture      deep
1 tree_0064.jpg  Populus       0.737   0.357 |     0.285     0.432     0.548     0.217
2 tree_0089.jpg  Populus       0.706   0.417 |     0.439     0.461     0.489     0.288
3 tree_0016.jpg  Populus       0.651   0.537 |     0.333     0.729     0.668     0.485
4 tree_0088.jpg  Populus       0.647   0.546 |     0.431     0.791     0.595     0.398
5 tree_0019.jpg  Populus       0.645   0.551 |     0.416     0.666     0.817     0.386
Thoi gian (ms): load_normalize=3.2, remove_background=263.4, extract_color=12.9, extract_shape=24.4,
extract_texture=113.6, extract_deep=6.9, candidates=2.0, distance_rank=0.8, total=427.7
```

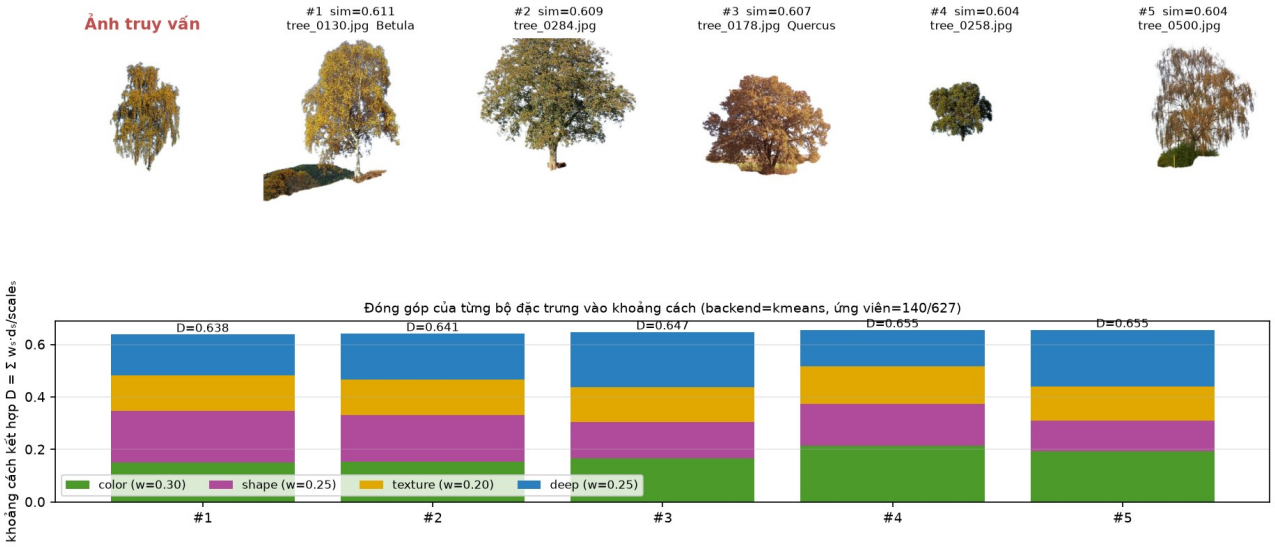


Hình 13. Kết quả top-5 cho ảnh query_03.jpg (backend kdtree)

Ví dụ 4: ảnh query_04.jpg (chi thật: Betula) với backend kmeans

Khoảng cách từ vector truy vấn đến 8 tâm cụm: cụm 0 = 1.114, cụm 7 = 1.196, cụm 1 = 1.320, cụm 4 = 1.358, cụm 5 = 1.400, cụm 6 = 1.414, cụm 2 = 1.490, cụm 3 = 1.559. Hệ thống quét các cụm [0, 7] (140 ảnh / 627) rồi xếp hạng chính xác.

```
Anh truy van: C:\Projects\MyProject\CSDL-DPT\data\queries\query_04.jpg  (ti le vung cay: 17.39%)
Backend: kmeans  | ung vien: 140/627  | trong so: color=0.30, shape=0.25, texture=0.20, deep=0.25
  dac trung [color] dim=225: hsv_fg(72), hsv_grid(144), moments(9)
  dac trung [shape] dim=113: region(10), hu(7), grid(64), fourier(16), profile(16)
  dac trung [texture] dim=85: glcm(10), lbp(28), edge(9), tamura(3), dct(35)
  dac trung [deep] dim=1280: mobilenetv2_gap(1280)
# anh            chi             sim       D |     color     shape   texture      deep
1 tree_0130.jpg  Betula        0.611   0.638 |     0.501     0.783     0.677     0.625
2 tree_0284.jpg                0.609   0.641 |     0.508     0.712     0.675     0.702
3 tree_0178.jpg  Quercus       0.607   0.647 |     0.558     0.551     0.662     0.837
4 tree_0258.jpg                0.604   0.655 |     0.711     0.644     0.711     0.555
5 tree_0500.jpg                0.604   0.655 |     0.645     0.462     0.650     0.866
Thoi gian (ms): load_normalize=6.4, remove_background=315.9, extract_color=6.7, extract_shape=11.0,
extract_texture=34.5, extract_deep=3.8, candidates=0.4, distance_rank=0.5, total=379.5
```



Hình 14. Kết quả top-5 cho ảnh query_04.jpg (backend kmeans)

5.3. Đánh giá kết quả

Phương pháp

Vì bộ dữ liệu có nhãn chi (genus) suy ra từ category nguồn, hệ thống đánh giá theo cách leave-one-out: lần lượt lấy từng ảnh có nhãn thuộc các chi có ≥ 5 ảnh làm truy vấn (257 truy vấn, các chi: Acacia (5), Alnus (12), Betula (25), Juglans (33), Pinus (46), Populus (61), Quercus (57), Tilia (10), Vachellia (8)), tìm top-5 trong 626 ảnh còn lại và tính: P@5 (tỉ lệ ảnh trong top-5 cùng chi), P@1, mAP@5, và P@5 theo nhóm hình thái (lá rộng/lá kim). Đường cơ sở ngẫu nhiên: P@5 = 0.068 theo chi và 0.333 theo nhóm. Lưu ý nhãn chi là tiêu chí khắt khe: hai cây cùng chi chụp ở mùa khác nhau có thể trông rất khác, và hai cây khác chi có thể có dáng rất giống nhau; con số tuyệt đối vì vậy thấp hơn cảm nhận trực quan về "ảnh giống nhau".

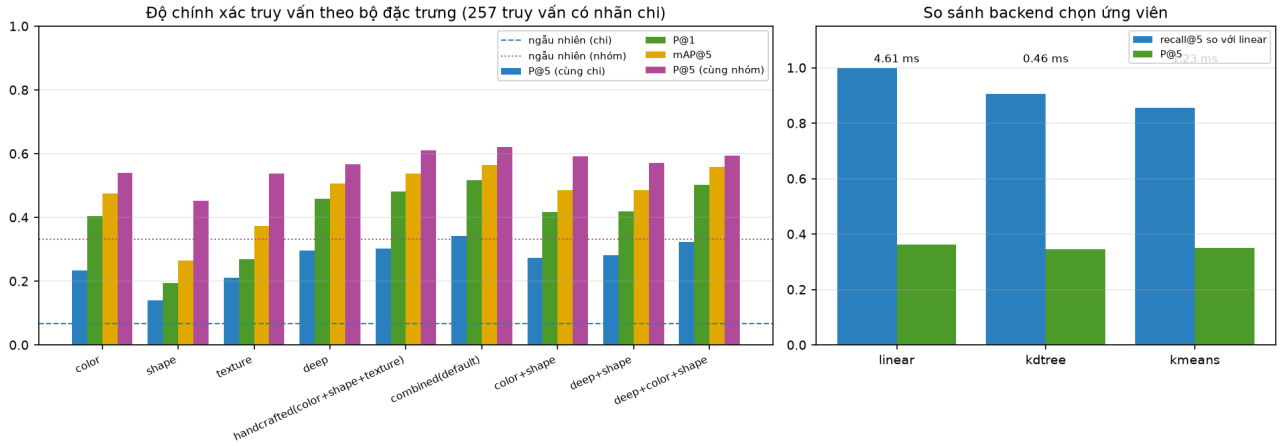
Bảng 21. Độ chính xác truy vấn theo từng bộ đặc trưng và các cách kết hợp (backend linear)

Cấu hình đặc trưng	P@5 chi	P@1 chi	mAP@5	P@5 nhóm	ms/truy vấn
color	0.234	0.405	0.476	0.539	5.6
shape	0.140	0.195	0.265	0.452	5.9
texture	0.212	0.268	0.374	0.539	5.7
deep	0.296	0.459	0.508	0.567	5.6
handcrafted(color +shape+texture)	0.304	0.482	0.538	0.612	5.6
combined(default)	0.343	0.518	0.564	0.620	5.3
color+shape	0.273	0.416	0.486	0.593	5.2
deep+shape	0.282	0.420	0.486	0.572	5.0

deep+color+shape	0.324	0.502	0.559	0.595	4.8
(ngẫu nhiên)	0.068	—	—	0.333	—

Bảng 22. So sánh các chiến lược chọn ứng viên (cấu hình trọng số mặc định, 150 truy vấn)

Backend	Recall@5 so với linear	P@5 chi	mAP@5	ms/truy vấn (xếp hạng)
linear	1.000	0.361	0.578	4.61
kdtree	0.905	0.347	0.577	0.46
kmeans	0.855	0.351	0.580	1.23



Hình 15. Độ chính xác theo bộ đặc trưng (trái) và so sánh backend (phải)

Nhận xét

- Mọi bộ đặc trưng đều vượt xa đường cơ sở ngẫu nhiên (P@5 theo chi 0.068): màu sắc đạt 0.234, kết cấu 0.212, hình dạng 0.140, embedding 0.296.
- Trong các đặc trưng thủ công, màu sắc mạnh nhất vì mùa/loại lá/bối cảnh gắn chặt với chi trong bộ dữ liệu (ví dụ thông luôn xanh sẫm, bạch dương thân trắng); hình dạng yếu nhất khi dùng riêng vì cùng một chi có nhiều dáng (tuổi cây, cắt tỉa, gió) và hình bao chỉ là hình chiếu 2D, nhưng bổ sung tốt khi kết hợp: ba bộ thủ công gộp lại đạt P@5 = 0.304 (mAP 0.538), cao hơn từng bộ riêng lẻ.
- Kết hợp cả bốn bộ với trọng số mặc định đạt P@5 = 0.343, P@1 = 0.518, mAP@5 = 0.564; theo nhóm lá rộng/lá kim đạt 0.620 so với ngẫu nhiên 0.333. Cấu hình tốt nhất trong thử nghiệm là "combined(default)" với P@5 = 0.343.
- Cây k-d trên PCA giữ được 90.5% kết quả top-5 của quét tuyến tính với thời gian xếp hạng giảm khoảng 10 lần; K-means giữ 85.5% khi chỉ quét ≥ 2 cụm. Với 627 ảnh,

quét tuyến tính vẫn chỉ mất ~5 ms nên được dùng mặc định; chỉ mục phát huy tác dụng khi CSDL lớn hơn nhiều.

- Thời gian trả lời một truy vấn hoàn chỉnh (kể cả tách nền và trích rút) khoảng 0,7–1,2 giây trên CPU, trong đó tách nền bằng SegFormer và trích rút đặc trưng chiếm phần lớn.
- Hạn chế: nhãn chi tự động từ category có thể sai/thiếu; phân đoạn đôi khi gộp hàng cây hậu cảnh dính liền tán vào vùng cây; các đặc trưng thủ công nhạy với ánh sáng và mùa; embedding ImageNet không được huấn luyện riêng cho cây. Hướng cải thiện: tinh chỉnh mạng trên dữ liệu cây, học trọng số kết hợp từ phản hồi người dùng (relevance feedback), phân đoạn từng cây (instance segmentation) để tách cây chính khỏi hàng cây phía sau.

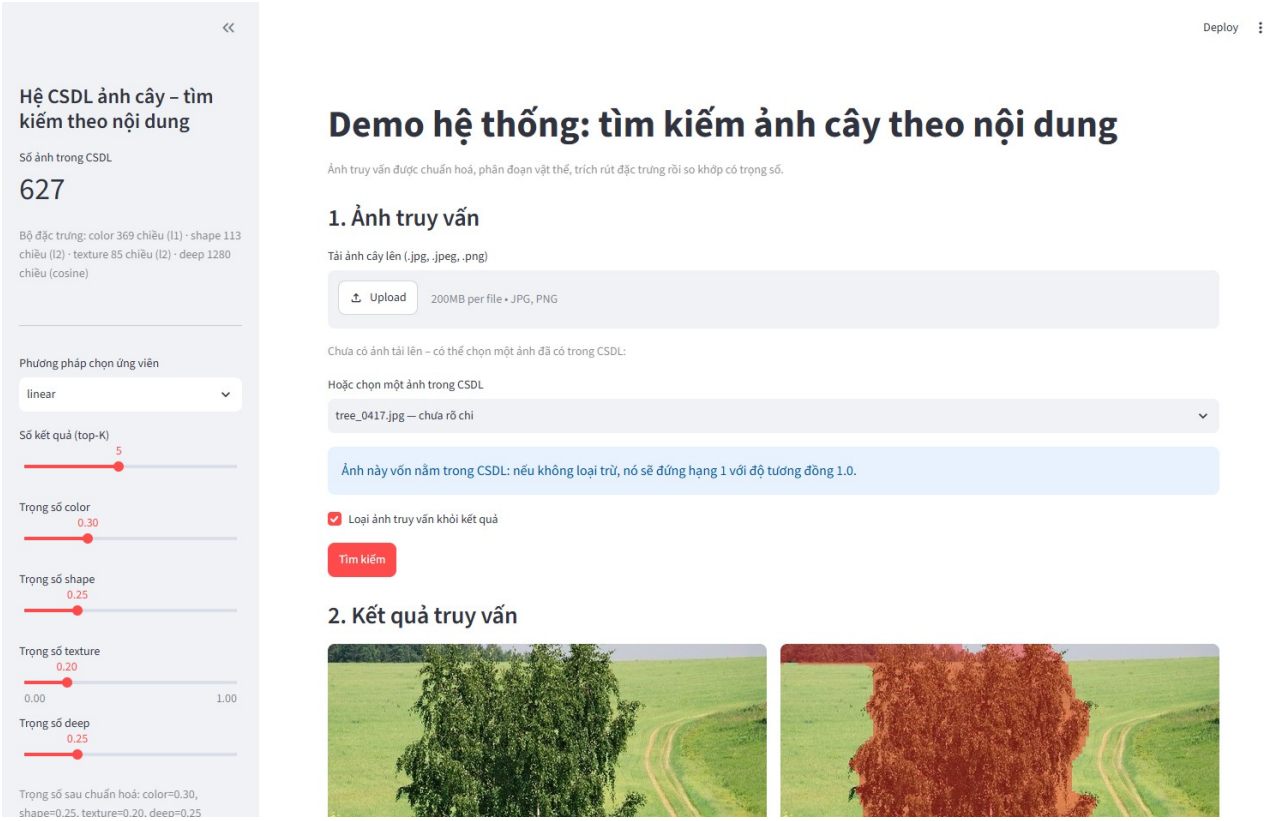
6. Demo hệ thống (Nội dung 5)

Hệ thống có hai cách sử dụng: giao diện web Streamlit và dòng lệnh.

6.1. Giao diện web

```
streamlit run app/streamlit_app.py
```

Thanh bên hiển thị thống kê CSDL (số ảnh, các bộ đặc trưng), cho phép chọn backend (linear / kdtree / kmeans), số kết quả K và trọng số từng bộ đặc trưng. Người dùng tải lên một ảnh cây bất kỳ (JPG/PNG) hoặc chọn một ảnh có sẵn; hệ thống hiển thị ảnh đã chuẩn hoá cùng ảnh sau tách nền, bảng thời gian xử lý, 5 ảnh giống nhất kèm độ tương đồng, bảng khoảng cách chuẩn hoá và đóng góp của từng bộ, biểu đồ các giá trị đặc trưng trung gian (biểu đồ HSV, lưới hình dạng, profile, LBP, GLCM, DCT) và, với backend chỉ mục, thông tin ứng viên/cụm được quét.



Hình 16. Giao diện demo Streamlit

6.2. Dòng lệnh

```
python scripts/query.py --image data/queries/query_01.jpg --backend linear --top-k 5 \
       --weights color=0.3,shape=0.25,texture=0.2,deep=0.25 --json out.json --fig out.png
```

Lệnh in bảng kết quả (như các khối văn bản ở mục 5.2), ghi toàn bộ giá trị trung gian ra JSON và vẽ hình kết quả.

7. Kết luận và hướng phát triển

Bài tập đã hoàn thành đầy đủ năm yêu cầu: (1) sưu tầm và chuẩn hoá bộ dữ liệu 627 ảnh cây thân gỗ đơn lẻ, cùng kích thước, có siêu dữ liệu nguồn/giấy phép và nhãn chi, kèm mô tả điểm giống/khác; (2) thiết kế bốn bộ đặc trưng (màu sắc, hình dạng, kết cấu/bố cục, embedding sâu) với phân tích giá trị thông tin của từng khối; (3) cài đặt các thuật toán trích rút và hệ CSDL SQLite quản trị đặc trưng theo mô hình lai cùng chỉ mục k-d tree và K-means; (4) xây dựng hệ thống tìm kiếm trả về 5 ảnh giống nhất với đầy đủ giá trị trung gian, đạt P@5 = 0.343 theo chi (gấp 5.1 lần ngẫu nhiên); (5) demo bằng giao diện web và dòng lệnh.

Hướng phát triển: mở rộng bộ dữ liệu với nhãn loài do chuyên gia gán; áp dụng phản hồi liên quan để cập nhật trọng số và vector truy vấn (công thức Rocchio); phân đoạn theo

từng thể hiện cây (instance segmentation); tinh chỉnh mạng nơ-ron trên ảnh cây; triển khai CSDL vector (FAISS/pgvector) khi số ảnh lên hàng triệu.

Phụ lục A. Cấu trúc mã nguồn và hướng dẫn chạy

```
CSDL-DPT/
  data/images_nobg/         ảnh CSDL 512x512 đã tách nền data/manifest.csv
  data/images/              ảnh chuẩn hoá (còn nền), đầu vào bước tách nền
  data/queries/             ảnh truy vấn thử            data/queries.csv, data/manual_exclude.csv
  db/tree_features.sqlite   CSDL đặc trưng
  src/treedb/config.py      cấu hình chung
  src/treedb/collect.py     sưu tầm ảnh (Wikimedia Commons API)
  src/treedb/preprocess.py  chuẩn hoá, khử trùng lặp, kiểm duyệt, tách ảnh truy vấn
  src/treedb/segment.py     tách nền: phân đoạn vật thể / nền (SegFormer, dự phòng GrabCut)
  src/treedb/segformer.py   mô hình phân đoạn ngữ nghĩa SegFormer-b0 ADE20K (ONNX)
  src/treedb/analysis.py    phân tích giá trị thông tin của đặc trưng (Fisher, 1-NN)
  src/treedb/features/      color.py, shape.py, texture.py, deep.py, __init__.py (extract_all)
  src/treedb/db.py          lược đồ và thao tác SQLite
  src/treedb/index.py       chuẩn hoá, khoảng cách, PCA, cây k-d, K-means
  src/treedb/search.py      pipeline truy vấn (Searcher), giải thích kết quả
  src/treedb/evaluate.py    đánh giá leave-one-out
  src/treedb/visualize.py   hình minh hoạ
  scripts/                  build_dataset, extract_features, build_index, run_evaluation,
make_figures,
                            query, build_docs
  app/streamlit_app.py      demo web
  results/                  evaluation.json, index_meta.json, query_examples/, excluded_images.csv
  docs/                     báo cáo (docx, pdf) và figures/
```

```
pip install -r requirements.txt
python scripts/build_dataset.py       # 1. sưu tầm + chuẩn hoá
python scripts/extract_features.py    # 2-3. tách nền, trích rút, ghi CSDL
python scripts/build_index.py         # 3b. chỉ mục kd-tree + K-means
python scripts/run_evaluation.py      # 4c. đánh giá
python scripts/make_figures.py        # hình + ví dụ truy vấn
python scripts/build_docs.py          # sinh báo cáo
python scripts/query.py --image <anh.jpg>
streamlit run app/streamlit_app.py
```

Phụ lục B. Trích danh sách nguồn ảnh

Toàn bộ ảnh lấy từ Wikimedia Commons theo giấy phép mở; danh sách đầy đủ (tiêu đề, URL trang mô tả, tác giả, giấy phép) nằm trong data/manifest.csv. Dưới đây là 25 dòng đầu:

Bảng 23. Trích danh sách nguồn ảnh

File	Tiêu đề nguồn	Tác giả	Giấy phép	Chi
tree_0001.jpg	20110714Populus alba1.jpg	AnRo0002	CC0	Populus
tree_0002.jpg	20110716Populus alba.jpg	AnRo0002	CC0	Populus
tree_0003.jpg	20110802Walnussbaum Plankstadt1.jpg	AnRo0002	CC0	Juglans
tree_0004.jpg	20110802Walnussbaum	AnRo0002	CC0	Juglans

	Plankstadt2.jpg			
tree_0005.jpg	20110802Walnussbaum Plankstadt4.jpg	AnRo0002	CC0	Juglans
tree_0006.jpg	20111028Populus alba1.jpg	AnRo0002	CC0	Populus
tree_0007.jpg	20111028Populus alba2.jpg	AnRo0002	CC0	Populus
tree_0008.jpg	20111028Populus alba3.jpg	AnRo0002	CC0	Populus
tree_0009.jpg	20111028Populus × canadensis.jpg	AnRo0002	CC0	Populus
tree_0010.jpg	2012-04-22 19-34-32 Switzerland Kanton Schaffhausen Dör	Hansueli Krapf This	CC BY-SA 3.0	Juglans
tree_0011.jpg	20120212Kriegbach08.jpg	AnRo0002	CC0	Populus
tree_0012.jpg	20120212Kriegbach09.jpg	AnRo0002	CC0	Populus
tree_0013.jpg	20120212Kriegbach10.jpg	AnRo0002	CC0	Populus
tree_0014.jpg	20120212Kriegbach11.jpg	AnRo0002	CC0	Populus
tree_0015.jpg	20120212Kriegbach12.jpg	AnRo0002	CC0	Populus
tree_0016.jpg	20120902Populus x canadensis1.jpg	AnRo0002	CC0	Populus
tree_0017.jpg	20120903Populus x canadensis03.jpg	AnRo0002	CC0	Populus
tree_0018.jpg	20120903Populus x canadensis04.jpg	AnRo0002	CC0	Populus
tree_0019.jpg	20120903Populus x canadensis06.jpg	AnRo0002	CC0	Populus
tree_0020.jpg	20120903Populus x canadensis07.jpg	AnRo0002	CC0	Populus
tree_0021.jpg	20120904Alnus glutinosa01.jpg	AnRo0002	CC0	Alnus
tree_0022.jpg	20120904Alnus glutinosa02.jpg	AnRo0002	CC0	Alnus
tree_0023.jpg	20120904Alnus glutinosa08.jpg	AnRo0002	CC0	Alnus
tree_0024.jpg	20120920Populus x canadensis01.jpg	AnRo0002	CC0	Populus
tree_0025.jpg	20120920Populus x canadensis03.jpg	AnRo0002	CC0	Populus

Bảng 24. Các ảnh truy vấn thử (không nằm trong CSDL)

File	Tiêu đề nguồn	Chi	Nhóm
query_01.jpg	05 - шманаево Поле.jpg	Betula	broadleaf
query_02.jpg	20130116Alnus glutinosa09.jpg	Alnus	broadleaf
query_03.jpg	20150827Populus alba.jpg	Populus	broadleaf
query_04.jpg	Birke bei Ebersburg im Herbst.jpg	Betula	broadleaf
query_05.jpg	Pinus sylvestris TK 2023-05-06 4.jpg	Pinus	conifer
query_06.jpg	Walnut-tree 20041012 2599.JPG	Juglans	broadleaf
query_07.jpg	Dülmen, Wildpark, Herzteich -- 2020 -- 3398.jpg	Quercus	broadleaf
query_08.jpg	Arbol1.JPG	Populus	broadleaf
query_09.jpg	Kameldornbaum Sossusvlei.jpg	Vachellia	broadleaf
query_10.jpg	Saman de la Plaza Bolívar, La Pica.jpg	Samanea	broadleaf